

老年人的人格增强多模式抑郁症检测

王红红研究中心 北京福安
信息技术有限公司 北京, 北京, 中国 wa
nghonghong@fosafer.com

抽象的

本文介绍了我们针对 ACM MM 2025 上的多模态人格感知抑郁检测 (MPDD) 挑战的解决方案。我们提出了一种结合了人格特征的老年人多模态抑郁检测模型。我们引入了一种基于共同关注机制的多特征融合方法, 以有效地将 LLD、MFCC 和 Wav2Vec 特征集成到音频模态中。对于视频模态, 我们结合从 OpenFace、ResNet 和 DenseNet 中提取的表示来构建全面的视觉特征集。认识到人格在抑郁症检测中的关键作用, 我们设计了一个交互模块来捕获人格特质和多模态特征之间的关系。MPDD 老年人抑郁检测轨道的实验结果表明, 我们的方法显着提高了性能, 为老年人群多模式抑郁检测的未来研究提供了宝贵的见解。

CCS概念

- 计算方法 → 人工智能;
用计算 → 健康信息学;
- 信息系统 → 多媒体信息系统。

关键字

多模态抑郁症检测、变压器融合、多级特征

ACM参考格式:

王红红. 2025. 老年人的人格增强多模式抑郁症检测. ACM 亚洲多媒体 (MMAsia '25), 2025 年 12 月 9 日至 12 日, 马来西亚吉隆坡. ACM, 美国纽约州纽约市, 6 页. <https://doi.org/10.1145/3743093.3770965>

1 简介

抑郁症是一种普遍存在的精神健康疾病, 严重影响全世界数百万人的福祉和生活质量[1]。据世界卫生组织 (WHO) 统计, 全球约有 2.8 亿人患有

沮丧。《柳叶刀》全球疾病负担 (GBD) 研究数据显示, 2010 年至 2021 年间, 抑郁症成为导致伤残调整生命年 (DALY) 损失的第二大原因, 且其全球负担持续增加[15]。传统抑郁症筛查方法通常基于患者健康问卷 9 (PHQ-9), 该问卷使用 0 至 27 分的评分来评估抑郁症状。分数高于 4 表明存在抑郁症, 5-9 分表示轻度抑郁, 10-14 分表示中度抑郁, 15-19 分表示中重度抑郁, 20-27 分表示重度抑郁[20]。传统的抑郁症筛查方法依赖于自我报告的反应, 这使得它们容易受到偏见的影响, 并限制了其在捕捉抑郁症复杂和不断变化的本质方面的有效性, 特别是在检测精神状态的早期或微妙变化方面。

深度学习显着提高了抑郁症检测的性能。基于深度学习的抑郁症检测技术利用从测试对象收集的生理和行为数据, 包括语音、文本、视频和脑电图 (EEG) 信号。这些数据提供了有价值的抑郁症指标。抑郁症患者经常表现出基本发声频率降低、表现出与悲伤和恐惧相关的面部表情, 并表现出与 PHQ-9 项目一致思想和行为。因此, 研究人员专注于以各种方式检测抑郁症, 例如图像 [3,6,8]、语音 [9,14,19] 和文本 [2,5,17]。尽管每种方式都提供了有价值的信息, 但依赖单一来源限制了捕获信息的深度。与单模态方法相比, 多模态数据提供更全面和互补的信号, 显着提高检测性能[12,16,17]。

然而, 当前的抑郁症检测算法面临着几个关键挑战。首先, 大多数现有研究和公开数据集主要关注青少年, 而对老年人口的关注相对较少。这是一个关键的差距, 因为抑郁症状在不同年龄段的表现往往不同。例如, 研究表明, 与年轻人相比, 患有抑郁症的老年人通常表现出较低程度的愤怒和内疚, 但焦虑程度较高 [4, 7]。

其次, 在音频模态中, 最近的研究主要依赖于独立的单一特征类型, 例如 OpenSMILE 1 提取的低级描述符 (LLD)、手工制作的特征 (例如梅尔频谱图) 或来自预训练模型的高级嵌入。此限制也适用于其他模式, 例如视频和文本。然而, 使用单一类型的特征通常无法捕获音频信号的全部复杂性, 从而限制了模型有效检测抑郁相关线索的能力。这凸显了

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
MMAsia '25, Kuala Lumpur, Malaysia

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 979-8-4007-2005-5/25/12
<https://doi.org/10.1145/3743093.3770965>

¹<https://github.com/audeering/opensmile>




图 1: 概述 的我们的多模式抑郁症检测框架集成 人格特质。

多模式抑郁症检测中需要更丰富、更集成的多层次表示。

第三，现有的抑郁症检测研究往往忽视了人格特质的影响。研究已经发现某些人格特征与抑郁症的发病之间存在很强的相关性 [10, 13]。斯滕伯格等人。[18] 进行了一项为期 6 年的纵向研究，涉及 1,511 名基线时没有抑郁症的老年人。该研究确定了与抑郁症后期发展显著相关的三种人格特征：神经质增加、应对能力下降和自我效能感降低。研究发现，与一般人群相比，表现出这些特征的个体患抑郁症的可能性分别高出 3.6 倍、2.0 倍和 1.7 倍。

为了解决上述挑战，本研究提出了一种为老年人量身定制的多模式抑郁症检测框架。该方法结合了人格特质，能够对个体抑郁症特征进行自适应建模，从而增强个性化和模型相关性。此外，它还集成了音频和视频模式的多层次特征，以捕获更全面的抑郁行为表征。本研究的主要贡献如下。

(1) 我们提出了一种专为老年人设计的多模式抑郁症检测网络。在音频模式中，该模型从时域和频域捕获多级表示，以丰富抑郁语音的表征。引入共同注意机制来有效地融合这些特征。对于视频模式，我们通过连接从不同任务和预训练模型中提取的特征来增强面部表示。

(2) 我们设计了一个人格特质和多模态特征交互模块 (PTMFIM) 来建模之间的深层相关性

抑郁特征和个体人格特征。这使得网络能够更有效地适应抑郁表达的个性化模式。

2 提出的模型

所提出的框架如图 1 所示。该模型由两个分支组成，其中音频分支提取三个级别的声学特征以捕获语音的互补方面。这些特征使用共同关注机制进行编码和集成，以实现多粒度融合。在视频分支中，编码器处理并连接在不同级别获得的视觉特征。然后使用注意力静态池 (ASP) 模块将生成的音频和视觉特征聚合成话语级表示。为了融合跨模态特征，采用 Transformer Fusion 模块来融合多模态特征。为了捕捉人格特质和多模态特征之间的复杂关系，我们提出了人格特质和多模态特征交互模块 (PTMFIM)。PTMFIM 旨在学习个性嵌入和多模态表示之间的深层交互，从而实现更加个性化和上下文感知的抑郁症检测。然后，PTMFIM 输出特征被传递到抑郁症分类器，该分类器根据丰富的表示来预测抑郁程度。

2.1 视听多级特征融合

在音频分支中，我们首先使用开源工具 OpenSMILE 从原始语音中提取 LLD，捕获基本的声学属性，例如短期能量和过零率。此外，广泛采用的梅尔倒谱系数 (MFCC) [2]

²<https://github.com/librosa/librosa>




图 2: 多模态特征和人格特质迭代模块。

在语音处理中，被提取来表示音频信号的短期频谱特征。为了进一步丰富表示，我们利用预训练的 Wav2Vec 模型 3 来提取高维音频嵌入。Wav2Vec 经过大量未标记音频的训练，提供了封装复杂声学模式的信息表示。所有三种类型的特征（LLD、MFCC 和 Wav2Vec 嵌入）均使用 LSTM 编码器进行编码，以保留时间依赖性并为后续融合做好准备。基于已知对抑郁症检测有独特贡献的不同听觉特征，并在[21]的见解的指导下，我们提出了一个共同注意模块来有效地集成 Wav2Vec、LLD 和 MFCC 特征。集成过程从使用线性层结合 Dropout 和 ReLU 激活对每种特征类型进行非线性变换开始。接下来，LLD 和 MFCC 特征沿着特征维度连接起来。由于 Wav2Vec 提供了高级语音表示，因此这些连接的特征用于通过逐元素乘法对 Wav2Vec 特征进行加权。最后，将加权的 Wav2Vec 特征与 LLD 和 MFCC 特征连接起来，形成全面的音频表示。

对于视频模式，首先使用 OpenFace 工具包 4 从原始视频帧中提取面部特征。为了进一步丰富表示，我们还使用预训练的 DenseNet 5 和 ResNet 6 架构提取互补特征，这两种架构都广泛用于图像分类任务。最后，将所有三个来源的输出连接起来形成全面的视觉表示。

2.2 个性与多模态特征交互模块

对于2.1节中提取的多模态表示，我们最初使用ASP将帧级特征转换为话语级特征。随后，采用 Transformer Fusion 模块来融合视觉和音频功能。假设 u_n^v 和 u_n^a 代表第 n 个样本的视觉和听觉特征，则多模态表示 f_s^* 可以表示为：

$$f_s^* = F_s^* (\text{Concat} (F_s^v (u_n^v), F_s^a (u_n^a)))$$

其中， F_s^a 是基于 LSTM 和 ASP 的声学编码器， F_s^v 是与 F_s^a 结构相同的视觉编码器。 F_s^* 表示 Transformer 融合模块，由多层 Transformer 编码器组成。连接的音频和视觉序列特征被输入到网络中，其中应用自注意力来捕获跨模式的远程依赖性。输出是一个统一的抑郁症表示，富含全局上下文信息。

要提取人类性格特征，第一步涉及构建患者提示。该提示源自患者的 Big5 评分、年龄、性别、籍贯和其他相关人口统计信息。具体提示如下：

患者是一名来自北京的50岁男性。患者的外向性评分为外向性。宜人性分数是宜人性。开放性分数是开放性。神经质分为神经质。责任心分数是责任心。请生成简洁、流利的英语描述，总结患者的主要性格特征、家庭环境和其他显著特征。避免提及抑郁症或相关术语。将响应输出为单个段落。

随后，采用 ChatGLM3 中文大语言模型 7 根据构建的提示生成个性化文本描述。然后使用 RoBERTa-large 模型对该描述进行编码，以获得个性化的抑郁症文本嵌入。

受[11]的启发，我们提出了PTMFIM，它对人格特质和多模态特征之间的复杂相关性进行建模，以学习深层的个性化交互模式。如图 2 所示，所提出的模块由三个关键组件组成：二元相关注意、三重交互注意和门控调节器。二元相关注意组件使用交叉注意机制来捕获人格特质和多模态表示之间的成对关系。为了实现这一点，线性投影层首先将人格特质和多模态特征映射到相应的查询 (Q)、键 (K) 和值 (V) 向量。然后应用注意力机制来捕获人格特质和多模态特征之间的潜在相关性。在此基础上，三重交互注意力组件进一步模拟了人格特征和融合视听特征之间的高阶交互，从而能够更深入地了解它们对抑郁检测的共同影响。级联交互表示由下式计算

³<https://github.com/facebookresearch/fairseq/tree/main/examples/wav2vec>

⁴<http://multicomp.cs.cmu.edu/resources/openface/>

⁵<https://github.com/liuzhuang13/DenseNet>

⁶<https://huggingface.co/microsoft/resnet-50>

⁷<https://github.com/THUDM/ChatGLM3>

使用个性特征作为查询向量，而二元相关注意力的输出作为键和值向量。最后，门调节器通过引入模拟人格特质和多模态表示之间关系的影响的门控机制，自动学习二元和高阶（三元）交互特征。该组件允许模型动态调整个性和多模态特征对抑郁症检测的贡献。具体来说，使用 sigmoid 函数根据二元相关注意力和三重交互注意力模块的输出来计算控制门值。然后，通过逐元素乘法将该门值应用于三重交互注意力的输出。随后，门控输出与个性特征嵌入相结合，产生交互模块的最终输出。

3 实验及结果

3.1 数据集

我们使用 2025 年 ACM 多媒体会议上举行的多模态人格感知抑郁检测 (MPDD) 挑战 8 的数据进行了一系列实验。该数据集使用 1 秒和 5 秒采样窗口进行特征提取处理，产生 564 个样本，其中 337 个用于训练和验证，227 个用于测试。1s 和 5s 都不表示样本的长度。相反，它们指的是预处理阶段使用的跳跃窗口的大小。由于训练数据量有限，训练时采用重采样策略。为了解决样本变异性，我们随机划分训练集和验证集，以确保数据的代表性分布。MPDD 根据抑郁症严重程度定义了三种分类任务。这些任务对应于二元、三元或五元分类方案，具体取决于所使用的标准。二元分类系统区分健康状态和抑郁状态。三元分类系统涉及正常、轻度和重度抑郁症的额外划分。另一方面，五元分类系统通过区分正常、轻度抑郁、中度抑郁、中度严重和重度抑郁，增加了额外的复杂性。通过平均加权和未加权精度以及加权和未加权 F1 分数来评估性能，从而全面衡量模型在多类抑郁症检测中的有效性。每个任务的最终指标是加权值和未加权值的平均值：

$$Acc^{task} = \frac{Acc_{weighted} + Acc_{unweighted}}{2}$$

$$F_1^{task} = \frac{F_{1,weighted} + F_{1,unweighted}}{2}$$

表 1 展示了我们提出的方法与 MPDD 在测试集上提供的基线模型的比较分析。基线采用每个音频和视频模态的单个特征，将人格特质特征直接与多模态表示连接起来。选择音频和视频特征排列实验中表现最好的结果作为基线结果。我们的方法显示出显著的改进

表 1: 所提出的方法与基线模型相比的结果，其中基线高于，建议低于

Length	Task	Accuracy	F1-score
1s	Binary	85.01	82.42
		89.18	88.53
	Ternary	55.95	56.06
		59.16	58.53
	Quinary	57.51	47.53
		61.33	60.67
5s	Binary	78.09	77.06
		79.81	78.67
	Ternary	58.66	58.80
		63.99	62.62
	Quinary	67.96	67.01
		72.17	72.48

所有三个多类分类任务的基线，适用于 1 秒和 5 秒采样窗口长度。在使用 1 秒采样窗口的三个分类任务中，我们的模型优于基线，平均准确率提高了 4.17%、3.21% 和 3.82%，F1 分数分别提高了 6.11%、2.47% 和 13.14%。在 5 秒采样窗口下，模型的准确度分别提高了 4.41%、5.9% 和 4.21%，F1 分数分别提高了 7.9%、13.8% 和 0.47%。这些结果证明了我们提出的方法的有效性。

3.2 突出模块的消融研究

本节通过消融实验验证每个提出的组件。表 2 比较了四种变体：(1) 没有音频多特征融合。(2) 音频特征融合中没有 Co-Attention。(3) 没有视觉多特征串联。(4) 无 PTMFIM。表 2 显示了使用 1 秒采样窗口的消融实验的结果。定量分析表明，所有提出的模块都对性能有积极贡献。在所提出的模块中，PTMFIM 的影响最大，在三个分类任务中分别将平均准确率提高了 2.89%、2.23% 和 3.27%，平均 F1 分数分别提高了 2.60%、3.18% 和 5.69%。这些结果强调了将人格特征与多模态表征相结合以增强抑郁症检测的有效性。此外，采用多个音频和视频特征以及用于音频特征融合的共同注意机制，与单特征基线相比获得了一致的性能增益。

此外，使用 5 秒采样窗口的消融实验（如表 3 所示）证实，每个提出的组件都在不同程度上有助于提高性能。与 1s 采样窗口类似，音频特征融合的 Co-Attention 机制和 PTMFIM 模块在改善抑郁症检测性能方面发挥了显著的作用。此外，多音频/视觉方法改进了最终结果，表明多尺度特征提供了补充信息

⁸<https://hacilab.github.io/MPDDChallenge.github.io/>

表 2: 1s 采样窗口的消融实验结果

Method	Task	Accuracy	F1-score
Baseline	Binary	85.01	82.42
	Ternary	55.95	56.06
	Quinary	57.51	47.53
w/o Multi-Audio	Binary	87.90	86.77
	Ternary	59.08	58.22
	Quinary	60.00	59.77
w/o co-att	Binary	88.89	87.74
	Ternary	58.98	58.33
	Quinary	57.73	54.24
w/o Multi-Visual	Binary	88.63	87.01
	Ternary	58.88	56.00
	Quinary	56.09	56.88
w/o PTMFIM	Binary	86.29	85.93
	Ternary	56.93	55.35
	Quinary	58.06	54.98
Proposed	Binary	89.18	88.53
	Ternary	59.16	58.53
	Quinary	61.33	60.67

表 3: 5s 采样窗口的消融实验结果

Method	Task	Accuracy	F1-score
Baseline	Binary	78.09	77.06
	Ternary	58.66	58.80
	Quinary	67.96	67.01
w/o Multi-Audio	Binary	79.30	78.34
	Ternary	61.38	59.85
	Quinary	70.14	69.51
w/o co-att	Binary	77.30	77.53
	Ternary	60.35	59.52
	Quinary	68.74	68.36
w/o Multi-Visual	Binary	78.78	77.75
	Ternary	59.90	59.91
	Quinary	70.25	69.29
w/o PTMFIM	Binary	78.66	77.91
	Ternary	59.08	58.78
	Quinary	68.30	66.82
Proposed	Binary	79.81	78.67
	Ternary	63.99	62.62
	Quinary	72.17	72.48

这有利于抑郁症的检测。这些结果进一步证明了我们的方法在不同采样尺度上的稳健性和有效性。

4结论

本研究提出了一种整合人格特征的老年人多模式抑郁症检测模型。对于音频模态，我们引入了一种基于联合注意力机制的多特征融合模块，该模块结合了三个特征。对于视频模式，三个不同的特征被串联起来。此外，我们提出了一个编码器来模拟人格特质和多模态特征之间的相互作用。对多模式人格感知抑郁症检测（MPDD）挑战的评估表明，我们的方法显著提高了老年人群的抑郁症检测性能。

参考

[1] Nasrin Abdoli, Nader Salari, Niloofar Darvishi, Sima Jafarpour, Mina Solaymani, Masoud Mohammadi 和 Shamarina Shohaimi. 2022.全球老年人重度抑郁症（MDD）患病率：系统评价和荟萃分析。神经科学与生物行为评论 132 (2022), 1067–1073. [2] Sergio G Burdisso, Marcelo Errecalde 和 Manuel Montes-y Gómez. 2019.一种文本分类框架，用于通过社交媒体流进行简单有效的早期抑郁症检测。专家系统与应用 133 (2019), 182–197. [3] 康斯坦丁诺·阿尔瓦雷斯·卡萨多、曼努埃尔·拉赫·卡涅利亚斯和米格尔·博尔达洛·洛佩斯。2023.使用面部视频的远程光电体积描记法识别抑郁症。IEEE 情感计算汇刊 14, 4 (2023), 3305–3316. [4] 艾米·菲斯克、朱莉·洛巴赫·韦瑟尔和玛格丽特·盖茨。2009年。老年人的抑郁症。临床心理学年度评论 5, 1 (2009), 363–389. [5] 付长增，陈正汉，施佳琪，吴博文，刘超然，卡洛斯·石纪德，石黑浩。2023. Hag：使用图网络进行分层注意力，用于对话中的对话行为分类。在 ICASSP 2023-2023 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。IEEE, 1-5. [6] 何朗，郭晨光，Prayag Tiwari, Hari Mohan Pandey, Wei Dang. 2022.基于面部表情的抑郁量表智能系统及工业智能案例研究。国际智能系统杂志 37, 12 (2022), 10140–10156. [7] JM Hegeman, RM Kok, RC Van Der Mast 和 EJ Giltay. 2012.老年人与年轻人相比的抑郁现象学：荟萃分析。英国精神病学杂志 200, 4 (2012), 275–281. [8] 胡斌，陶永峰，杨民强。2023.根据视频中情绪刺激引起的面部线索检测抑郁症。生物学和医学中的计算机 165 (2023), 107457. [9] Baljeet Kaur, Swati Rathi 和 RK Agrawal. 2022.使用量子鲸优化算法进行特征选择，增强语音抑郁检测。生物学和医学计算机 150 (2022), 106122. [10] AML Koorevaar, HC Comijs, ADF Dhondt, HWJ Van Marwijk, RC Van Der Mast, P Naarding, RC Oude Voshaar 和 ML Stek. 2013年。大五人格与老年人抑郁症的诊断、严重程度和发病年龄。情感障碍杂志 151, 1 (2013), 178–185. [11] 刘锐，左浩林，廉正，邢晓芬，Björn W Schuller, 李海洲。2024.多模态对话中的情感和意图联合理解：基准数据集。arXiv 预印本 arXiv:2407.02751 (2024). [12] Anupama Ray, Siddharth Kumar, Rutvik Reddy, Prerana Mukherjee 和 Ritu Garg. 2019.使用文本、音频和视频进行抑郁症预测的多级注意力网络。第九届国际视听情感挑战与研讨会论文集。81–88. [13] 纳斯林·萨德克和维克多·莫里纳里。2018.老年人的人格及其与抑郁和认知的关系：对实践的影响。临床老年学家 41, 5 (2018), 385–398. [14] Sara Sardari, Bahareh Nakisa, Mohammed Naim Rastgoo 和 Peter Eklund. 2022.使用卷积自动编码器进行基于音频的抑郁症检测。专家系统与应用 189 (2022), 116076. [15] Austin E Schumacher, Hmwe Hmwe Kyu, Amirali Ali, Cristiana Abbafati, Jaffar Abbas, Rouzbeh Abbasgholizadeh, Madineh Akram Abbasi, Mohammadreza Abbasian, Samar Abd ElHafeez, Michael Abdelmasseh 等。2024年。1950-2021年204个国家和地区以及811个国家以下地点的全球年龄-性别死亡率、预期寿命和人口估计，以及COVID-19流行的影响：2021年全球疾病负担研究的全面人口分析。《柳叶刀》403, 10440 (2024), 1989-2056. [16] 纳迪·塞内维拉特纳和卡罗尔·埃斯皮·威尔逊。2022.使用发音协调特征和基于分层注意力的文本嵌入进行多模式抑郁症分类。在 ICASSP 2022-2022 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。IEEE, 6252–6256.

[17] 沉瑛, 杨辉宇, 琳琳. 2022. 自动抑郁症检测: 情感音频文本语料库和基于 gru/bilstm 的模型。在 ICASSP 2022-2022 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。IEEE, 6247–6251。[18] Bas Steunenberg, Aartjan TF Beekman, Dorly JH Deeg 和 Ad JFM Kerkhof. 2006. 人格与晚年抑郁症的发作。情感障碍杂志 92, 2-3 (2006), 243–251。[19] 孙陈建, 姜敏, 高琳琳, 于欣, 董一红。2024. 一项基于图神经网络的使用音频信号检测抑郁症的新颖研究。

生物医学信号处理与控制 88 (2024), 105675。[20] 张兰, Kurt Fritzsche, 刘阳, 王健, 黄明金, 王宇, 陈亮, 罗善霞, 于建英, 董再全, 等。2016年, PH Q-15中文版在三级医院的验证。BMC 精神病学 16, 1 (2016), 89。[21] 邹鹤庆, 司玉可, 陈晨, Deepu Rajan, Eng Siong Chng. 2022. 基于多级声学信息的共同注意的语音情感识别。在 ICASSP 2022-2022 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。IEEE, 7367–7371。