

DepFormer: 用于抑郁症检测的双模协作 Transformer 统一框架

刘方圆* 中国科学技术大学 合肥, 中国 liufangyuan@mail.ustc.edu.cn 赵思锐*† 中国科学技术大学 合肥, 中国 Siruit@ustc.edu.cn 尹康* 中国科学技术大学 合肥, 中国 yingang@mail.ustc.edu.cn

徐童 中国科学技术
大学 中国合肥 tongxu@ustc.edu.cn

陈恩红† 中国科学技
术大学 中国合肥 cheneh@ustc.edu.cn

抽象的

抑郁症是世界范围内日益普遍的心理健康问题，特别是在老年人中，有效的早期发现对于及时干预至关重要。虽然最近的多模态方法证明了利用视觉和听觉线索进行自动抑郁症识别的前景，但现有方法通常无法从预先提取的特征中提取细粒度的抑郁症特定模式，并且未充分利用跨模态交互。为了应对这些挑战，我们提出了 DepFormer，这是一个统一的框架，其中包含用于跨模态表示学习的双模态协作变压器（BCT）和用于增强个体特定建模的个性化融合模块。该架构包括：（1）单峰特征提取，（2）通过 BCT 进行双峰协作表示学习，（3）个性化特征融合，以及（4）最终抑郁症分类。重要的是，BCT 采用由音频到视频转换器和视频到音频转换器组成的对称双向分支，以实现跨模态的相互增强和互补学习。大量实验验证了 DepFormer 的有效性，在 2025 年 MPDD 挑战赛（老年赛道）中获得第一名，凸显了其强大的实际潜力。

CCS概念

• 计算方法 → 人工智能。

关键字

情感计算、自动抑郁检测、多模态融合

*These authors contributed equally to this research.

†Corresponding authors: Sirui Zhao and Enhong Chen.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

MM '25, Dublin, Ireland

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 979-8-4007-2035-2/2025/10
<https://doi.org/10.1145/3746027.3762062>

ACM参考格式:

刘方圆, 赵思睿, 尹康, 徐同, 陈恩红. 2025. DepFormer: 用于抑郁症检测的双模协作变压器的统一框架. 第 33 届 ACM 国际多媒体会议 (MM' 25) 会议记录, 2025 年 10 月 27 日至 31 日, 爱尔兰都柏林. ACM, 美国纽约州纽约市, 7 页. <https://doi.org/10.1145/3746027.3762062>

1 简介

抑郁症是一种常见的致残性精神障碍，其特点是持续悲伤、兴趣丧失和认知能力下降。据世界卫生组织统计，全世界有超过 2.8 亿人患有抑郁症，且发病率持续上升，尤其是老年人¹。如果治疗不当，抑郁症可能会导致严重后果，例如社交退缩、生活质量下降，甚至自杀。这些风险强调了早期、可靠检测的必要性。鉴于传统的抑郁症临床访谈成本高昂且无法扩展，特别是面对不断增长的患者群体，开发自动检测系统已成为迫切需要[1]。

基于多模态数据（例如视频、音频和文本）的自动抑郁症检测已显示出巨大的前景。现有研究主要集中在两个关键方面：从每种模态中提取与抑郁症相关的特征，并将这些异质特征有效地融合成统一的表示。早期的工作采用 CNN 和 RNN 来捕获空间和时间模式 [2-8]，而最近的研究则利用基于 Transformer 的架构和 Mamba 等状态空间模型来改进远程时间建模 [9-15]。关于融合，方法多种多样，从单峰预测的决策级聚合 [16-18] 到分类前的特征级串联或投影 [16-18]。最近的方法探索模型级与跨模式注意机制的融合，以实现更丰富的交互 [10, 15, 19, 20]。

虽然这些方法取得了可喜的结果，但它们仍然面临两个关键限制：（1）从预先提取的特征（例如，MFCC、OpenFace）中提取抑郁症相关模式的不足，由于在隐私限制下无法获得原始数据，这些模式经常遭受语义损失和表达能力有限；（2）次优多模态融合策略未能充分

¹<https://www.who.int/news-room/fact-sheets/detail/depression>




图 1: DepFormer 概述。预先提取的音频和视频输入的时间特征通过双峰协作变压器与个性化信息进行细化，然后用于抑郁症分类。

利用不同模式的互补性。为了应对这些挑战，我们提出了 DepFormer，这是一个统一的框架，利用双模态协作变压器进行跨模态表示学习，并结合个性化特征融合来增强抑郁症检测。如图 1 所示，该模型从单峰特征提取模块开始，该模块从预先提取的特征序列中学习特定于模态的时间表示。然后将提取的表示输入双模态协作变压器，该变压器能够实现音频和视频特征之间的双向交互，从而允许每种模态通过交叉注意机制丰富另一种模态。为了进一步增强适应性，我们结合了个性化融合，将学习到的表征与个体特定特征相结合，以更好地反映受试者的变异性。最后，通过跨模式交互和个性化适应丰富的联合表示用于抑郁症分类。在基准数据集上的大量实验结果表明，我们的方法在抑郁症检测方面取得了优异的性能。

我们的主要贡献可以总结如下：

- 我们提出了一个用于多模态抑郁症检测的统一框架，该框架集成了双模态协作变压器和个性化融合，以有效地模拟时间依赖性和跨模态交互。
- 我们设计了一种双分支协作变压器结构，通过相互指导和互补学习促进特定模态的增强。
- 大量的实验证明了我们方法的有效性，我们在 MPDD 2025 [9] 老年人追踪中获得了排名 1，凸显了我们方法的实用价值和鲁棒性。

2 相关工作

2.1 多模态抑郁症检测

近年来，自动抑郁症检测引起了越来越多的关注，特别是随着音频和视频等多模态行为数据的出现。然而，与许多其他多模态任务不同，抑郁症检测通常涉及敏感信息，由于隐私问题，使得原始音频和视频数据的收集和发布变得困难。结果，数据集

如 DAIC-WOZ[21]、D-Vlog[10] 和 MPDD[9] 仅提供预提取的特征而不是原始视频和音频，这给抑郁症检测带来了新的挑战。

多模式抑郁症检测的早期研究依赖于手工制作的特征。使用 LBP 和 LBP-TOP [22, 23] 等局部描述符捕获视觉线索，而 MFCC [24] 和 LIWC [25] 通常分别用于音频和文本。尽管可解释且易于实现，但这些方法严重依赖于手动设计的功能，限制了它们对复杂模式进行建模和推广到现实世界场景的能力。

深度学习的最新进展使得能够从多模态特征中进行更丰富的表示学习。为了对时间视觉动力学进行建模，基于 CNN 的方法已被广泛探索，通常使用 3D CNN 或 2D CNN 与时间模块（例如注意力卷积）相结合 [2-5]。然而，这些方法在捕获远程依赖性方面受到限制。为了解决这个问题，引入了基于 RNN 的模型，特别是使用 LSTM 单元的模型，以更好地捕获视觉和听觉线索的时间进展。这些方法 [6-8] 利用顺序建模来捕捉情绪相关线索的动态变化。虽然此类模型增强了顺序建模，但它们对现实世界抑郁症分析的推广仍然有限，特别是在不同的主题条件和不同的记录环境下 [26]。

最近，基于 Transformer 的架构 [9-14] 和 Mamba 基于模型 [15] 已应用于抑郁症检测，通过注意力或状态空间机制提供增强的远程依赖性建模。例如，尹等人。[10] 提出了一种基于 Transformer 的具有交叉注意力的多模态模型，以有效捕获跨声学 and 视觉特征的关系，而 Ye 等人。[15] 引入了 Dep Mamba，利用 Mamba 进行分层上下文建模和渐进融合。基于这些进展，我们引入了一个统一的框架，其中包含用于双模表示学习和个性化抑郁严重程度分类的双模协作变压器。

2.2 多模态融合方法

近年来，整合来自音频和视频等异构源的线索的多模态融合技术对于改善抑郁症检测变得非常重要。这些多式联运

融合方法通常可以分为特征级、决策级和模型级融合策略。

特征级融合涉及连接来自各种模态的特征，以在分类之前学习统一的表示[16-18]。例如，Fu 等人。[16]通过基于图的时间注意力模型集成面部动作单元和语音特征来提取互补的情感特征，从而融合面部动作单元和语音特征，以增强抑郁症检测。然而，在组合异构模态时，特征级融合可能会遇到特征不兼容和高维度的问题。

或者，决策级融合将单一模态训练的模型的预测进行整合，以达到集体分类[27-30]。张等人。[28]提出了一种使用多智能体系统的决策级方法。虽然简单，但决策级融合缺乏模态之间的深度交互，可能限制其捕获微妙的跨模态相关性的能力。

模型级融合在模型架构中纳入了跨模式交互，允许更集成的学习[10,15,19,20]。陶等人。[20]提出了 DepMSTAT，一个模型级融合框架，它通过统一的变压器联合捕获时空声学 and 视觉特征，用于抑郁症检测。相比之下，我们的工作探索了不同的方向，利用双模态协作转换器通过相互细化动态增强特定于模态的表示，进一步结合个性化特征以进行稳健的分类。

3方法

在本节中，我们提出了我们提出的DepFormer，一个统一的多模态抑郁症检测框架，它集成了声学、视频和个性化特征以实现有效的抑郁症检测。我们模型的核心思想是首先提取特定于模态的时间表示，然后通过双模态协作变压器对其进行增强，最后合并个性化信息以形成最终分类的统一表示。整个架构由四个关键阶段组成：单峰特征提取、双峰协作表示学习、个性化特征融合和抑郁分类。该模型的概述如图 1 所示。

3.1 单峰特征提取

在我们模型的第一阶段，我们独立地编码声音和视频时间序列。鉴于音频和视频数据固有的顺序性质，我们采用长短期记忆（LSTM）网络来捕获每种模态内的时间依赖性。这使得模型能够学习特定于模态的表示，从而保留重要的时间动态。

令声学 and 视频特征序列表示为 $X_a \in \mathbb{R}^{T_a \times D_a}$ 和 $X_v \in \mathbb{R}^{T_v \times D_v}$ ，其中 T_a 和 T_v 表示序列长度， D_a 和 D_v 分别是声学 and 视频模态的特征维度。

我们采用两个独立的 LSTM 编码器来对每种模态的时间结构进行建模，输出计算如下：

$$L_a = \text{LSTM}_{\text{audio}}(X_a), \quad L_v = \text{LSTM}_{\text{video}}(X_v). \quad (1)$$

每个 LSTM 编码器都会生成一系列高级表示，然后在每个 LSTM 编码器上应用密集变换层。




图 2：双模式协作变压器图示。

时间步长：

$$F_a = \tanh(L_a W_a), \quad F_v = \tanh(L_v W_v), \quad (2)$$

其中 $W_a \in \mathbb{R}^{D_a \times d_{\text{model}}}$, $W_v \in \mathbb{R}^{D_v \times d_{\text{model}}}$ 是特定于每种模态的可学习投影矩阵。这种密集嵌入策略使模型能够将原始 LSTM 输出转换为紧凑的非线性特征空间，同时保留时间分辨率。然后将所得的特定模态嵌入 F_a 和 F_v 转发到双模态协作表示学习模块。

3.2 双模态协作表示学习

我们模型的一个关键组成部分是双模态协作变压器（BCT），它旨在实现声学 and 视频模态之间的深度交互。如图2所示，该模块由两个对称分支组成：音频到视频协作转换器和视频到音频协作转换器。每个分支都实现为一堆 N Transformer 层，其中每个层通过多头交叉关注来关注互补模态，从而细化一种模态的时间表示。

协作 Transformer 分支中的每一层都采用标准 Transformer 架构，其中自注意力被多头交叉注意力取代，以捕获模间依赖性。该层由交叉注意模块、残差连接、层归一化和前馈网络组成。

让 $M_{\text{attn}}^v \in \{0, -\infty\}^{T_v \times T_v}$ 和 $M_{\text{attn}}^a \in \{0, -\infty\}^{T_a \times T_a}$ 分别表示视觉和声学模态的注意力掩模。令 $F_a^{[i]}$ 和 $F_v^{[i]}$ 表示第 i 个 Transformer 层的输入声学 and 视觉特征，其中 $i \in \{1, \dots, N\}$ 。第一层的输入初始化为 $F_a^{[0]} = F_a$ 和 $F_v^{[0]} = F_v$ 。

下面详细介绍视频到音频分支的逐层计算，其中音频到视频分支遵循相同的结构，但模态角色相反：

(1)多头交叉注意力。我们首先将输入特征投影为查询、键和值表示：

$$Q_a^{[i]} = F_a^{[i]} W_Q, \quad K_v^{[i]} = F_v^{[i]} W_K, \quad V_v^{[i]} = F_v^{[i]} W_V, \quad (3)$$

其中 $W_Q, W_K, W_V \in \mathbb{R}^{d_{\text{model}} \times (hd_{\text{model}})}$ 是投影矩阵。投影的特征被重塑并分成 h 个头，每个头的维度为 d_{model} 。对于第 i 层和第 j 个注意力头，查询矩阵为 $Q_{a,j}^{[i]} \in \mathbb{R}^{T_a \times d_{\text{model}}}$ ，键和值矩阵为 $K_{v,j}^{[i]}, V_{v,j}^{[i]} \in \mathbb{R}^{T_v \times d_{\text{model}}}$ 。第 j 个头的注意力输出计算如下：

$$\text{head}_j^{[i]} = \text{softmax} \left(\frac{Q_{a,j}^{[i]} (K_{v,j}^{[i]})^\top + M_v^{[i]}}{\sqrt{d_{\text{model}}}} \right) V_{v,j}^{[i]}, \quad (4)$$

所有头的输出被连接并投影以形成最终结果：

$$\text{MultiHead}^{[i]} = \text{Concat}(\text{head}_1^{[i]}, \dots, \text{head}_h^{[i]}) W^O, \quad (5)$$

其中 $W^O \in \mathbb{R}^{(hd_{\text{model}}) \times d_{\text{model}}}$ 是输出投影矩阵。

(2) 添加&LayerNorm。应用残差连接和层归一化：

$$Z_a^{[i]} = \text{LayerNorm}(F_a^{[i]} + \text{MultiHead}(F_a^{[i]}, F_v^{[i]}, M_v^{\text{attn}})). \quad (6)$$

(3) 前馈和标准化。每个块都以前馈网络结束，然后是残差连接和层归一化：

$$F_a^{[i+1]} = \text{LayerNorm}(Z_a^{[i]} + \text{FFN}(Z_a^{[i]})), \quad (7)$$

其中 $\text{FFN}(\cdot)$ 表示具有 ReLU 激活的两层全连接网络。

为了获得固定长度的表示，我们在两个分支的最终层输出的序列长度维度上应用掩模平均池化。具体地， $F_a^{[N]}$ 表示 Video-to-Audio 分支的最终输出， $F_v^{[N]}$ 对应 Audio-to-Video 分支的最终输出。每种模态的全局表示可以表述为：

$$\begin{aligned} \hat{F}_a &= \text{MaskedAvgPool}(F_a^{[N]}, M_a^{\text{pool}}), \\ \hat{F}_v &= \text{MaskedAvgPool}(F_v^{[N]}, M_v^{\text{pool}}), \end{aligned} \quad (8)$$

其中 $M_a^{\text{pool}} \in \{0, 1\}^{T_a}$ 和 $M_v^{\text{pool}} \in \{0, 1\}^{T_v}$ 是用于忽略填充位置的二进制掩码。最终的双峰表示是通过连接特定于模态的嵌入来获得的：

$$F_{\text{bimodal}} = \text{Concat}(\hat{F}_a, \hat{F}_v). \quad (9)$$

3.3 个性化特征融合

由于 MPDD 数据集提供静态个性化特征 $P \in \mathbb{R}^{d_p}$ ，它捕获参与者特定的信息。为了将这些特征与动态双峰表示集成，我们首先通过线性层将维度为 d_p 的原始个性化特征 P 投影到模型的隐藏特征空间 $\mathbb{R}^{d_{\text{model}}}$ 中：

$$P' = \text{Linear}(P), \quad P' \in \mathbb{R}^{d_{\text{model}}}. \quad (10)$$

然后将个性化嵌入 P' 与双峰协作特征 F_{bimodal} 连接起来，形成最终的特征表示：

$$F_{\text{final}} = \text{Concat}(F_{\text{bimodal}}, P'). \quad (11)$$

这种融合策略允许模型利用静态参与者特定属性和动态视听特征来改进预测。

3.4 抑郁症分类

为了提高鲁棒性并减轻类别不平衡，我们采用双头分类策略。最终的融合表示 F_{final} 被输入两个并行分类器：一个使用交叉熵损失进行训练，另一个使用焦点损失进行训练。形式上，两组 Logit 由下式给出：

$$z_{\text{CE}} = \text{Classifier}_{\text{CE}}(F_{\text{final}}), \quad z_{\text{FL}} = \text{Classifier}_{\text{FL}}(F_{\text{final}}), \quad (12)$$

其中 z_{CE} 和 z_{FL} 是两个分类器预测的 logits。

总训练损失定义为：

$$\mathcal{L} = \mathcal{L}_{\text{CE}}(z_{\text{CE}}, y) + \lambda_{\text{FL}} \cdot \mathcal{L}_{\text{Focal}}(z_{\text{FL}}, y), \quad (13)$$

其中 $\mathcal{L}_{\text{CE}}$ 和 $\mathcal{L}_{\text{Focal}}$ 分别表示交叉熵和焦点损失函数， y 是真实标签， λ_{FL} 控制焦点损失的贡献。

在推理过程中仅使用分类器 CE ，同时对两个头进行联合训练以提高鲁棒性。最终的预测是通过对 logits z_{CE} 应用 softmax 来获得的：

$$\hat{y} = \text{softmax}(z_{\text{CE}}). \quad (14)$$

4 实验

4.1 数据集和评估指标

MPDD-Elderly 数据集是一个专注于老年人抑郁检测的多模态数据集。它包括视听记录和个性化信息，以更好地捕捉抑郁相关线索，同时考虑个体差异。每个样本都与所有三个分类方案相关联：二元（正常与抑郁）、三元（正常、轻度、严重）和五元（五级 PHQ-9 严重程度）。

为了进行评估，我们采用两个标准分类指标：准确度（Acc）和 F1 分数（F1）。计算加权和未加权版本以评估 MPDD-Elderly 数据集的性能。

4.2 实施详细信息

我们在两个分割窗口设置（1 秒和 5 秒剪辑）下评估三个分类任务（二元、三元和五元）的模型。该模型在 PyTorch 中实现，并使用 Adam 或 AdamW 优化器进行训练，超参数总结在表 2 中。

我们的模型是使用 PyTorch 实现的。所有实验均在配备 NV IDIA RTX 3090 GPU 的机器上进行。根据经验结果，我们将隐藏维度 d_{model} 设置为 256，Transformer 层数 N 设置为 1，注意力头数量 h 设置为 2，以平衡效率和性能。对于输入特征，我们使用基于 DenseNet 的视频视觉特征

表 1: 不同方法对 MPDD 老年人的结果 (%). (W/U: 加权/未加权)

Task	Window	Method	Audio	Video	Acc (W)	Acc (U)	F1 (W)	F1 (U)
Binary	1s	Baseline [9]	mfcc	openface	85.40	84.62	85.71	79.13
		DepMamba [15]	mfcc	densenet	85.72	94.27	93.98	89.15
		Ours	mfcc	densenet	88.75	96.03	95.83	92.48
	5s	Baseline [9]	opensmile	resnet	75.40	80.77	81.75	72.37
		DepMamba [15]	mfcc	densenet	73.75	90.75	89.35	79.55
		Ours	mfcc	densenet	91.25	96.92	96.80	94.29
Ternary	1s	Baseline [9]	opensmile	resnet	55.49	56.41	56.48	55.64
		DepMamba [15]	mfcc	densenet	71.88	74.32	74.23	72.85
		Ours	mfcc	densenet	81.55	86.34	85.93	83.23
	5s	Baseline [9]	wav2vec	openface	59.62	57.69	58.22	59.37
		DepMamba [15]	mfcc	densenet	72.82	69.47	69.37	68.65
		Ours	mfcc	densenet	85.21	81.50	81.73	81.45
Quinary	1s	Baseline [9]	opensmile	densenet	45.79	69.23	66.26	46.66
		DepMamba [15]	mfcc	densenet	48.87	77.09	73.10	49.55
		Ours	mfcc	densenet	70.23	81.50	76.82	73.38
	5s	Baseline [9]	mfcc	densenet	57.71	78.21	75.62	58.40
		DepMamba [15]	mfcc	densenet	61.54	78.85	75.78	55.62
		Ours	mfcc	densenet	70.08	79.30	76.2	67.71

表 2: 每个任务的训练超参数

Task	Optimizer	Batch Size	Learning Rate	Epochs
1s Binary	AdamW	8	2e-5	300
5s Binary	AdamW	2	1.8e-5	200
1s Ternary	Adam	4	4.58e-5	200
5s Ternary	Adam	4	4.58e-5	300
1s Quinary	Adam	1	9.8e-5	300
5s Quinary	Adam	1	9.75e-5	200

音频模态的模态和 MFCC，因为这些配置在我们的实证评估中产生了卓越的性能。在训练期间，每个批次中的输入序列都会被填充到该批次中的最大序列长度，并生成相应的注意掩码以确保正确的时间建模。欲了解更多详情，请参阅我们的代码²。

注意：对于最终的竞赛提交，我们采用两种策略来进一步提高模型性能。首先，对于 1 和 5 五元分类任务，我们通过对多个检查点的预测进行平均来执行集成学习，并根据其性能进行加权。其次，为了确保同一主题的剪辑之间的标签一致性，我们应用主题级投票策略。具体来说，由于每个受试者在测试集中可能有多个不重叠的剪辑，因此我们首先独立预测每个剪辑，然后在剪辑之间分配多数投票标签作为最终的受试者级预测，该预测将传播回所有关联的样本。

4.3 与现有方法的比较

我们将我们的方法与官方基线和最近最先进的模型 DepMamba [15] 进行比较，该模型采用渐进式视听融合策略进行多模式抑郁症检测。

²<https://github.com/lfy-ustc/MPDD25-Track1-Solution>

它利用卷积网络和 Mamba 层进行分层序列建模和多模态融合。为了确保公平比较，我们使用我们的集成策略将相同的个性化特征嵌入到复制的 DepMamba 模型中。所有方法均在 1 秒和 5 秒窗口设置下的 MPDD-Elderly 数据集的测试集上跨二元、三元和五元分类任务进行评估。

表 1 显示了 1 秒和 5 秒窗口设置下的二元、三元和五元分类任务的结果。我们的方法在所有设置中始终优于 DepMamba 和官方基线，在准确性和 F1 分数方面都取得了显著的进步。值得注意的是，性能优势适用于所有级别的标签粒度，从粗粒度（二元）到细粒度（五元）分类，显示了我们的方法在识别不同程度的抑郁症严重程度方面的有效性。

4.4 性能波动分析

鉴于 MPDD-老年人数据集中参与者之间固有的变异性（例如健康状况、个人特征），我们观察到不同训练运行中明显的表现波动。为了提供更全面的评估，我们通过重复每个实验 10 次来评估 MPDD-Elderly 测试集上的所有模型，报告准确度和 F1 的平均值和标准差，并进行配对 t 检验以评估显著性。

如表 3 所示，与 DepMamba 相比，我们的方法在所有任务中总体上实现了更高的平均准确率和 F1 分数。例如，在 5s 五元分类任务中，我们的模型达到了 68.09% 的平均准确率，标准差为 8.26，而 DepMamba 达到了 55.20%，但波动较大（std = 17.91）。在 F1 分数中观察到类似的模式（65.95 ± 7.97 与 50.04 ± 19.00）。正如配对 t 检验所示，这些改进不仅是实质性的，而且在大多数任务和指标中具有统计显著性。

表 3: 准确度和 F1 分数的平均值 $\pm$ SD (%), 对加权和未加权结果进行平均。星号表示相对于 DepMamba 的显著性 (配对 t 检验: * $p < 0.05$, ** $p < 0.01$)。

Task	Method	Acc	F1
1s Binary	DepMamba [15]	81.85 $\pm$ 8.23	81.81 $\pm$ 7.48
	Ours	81.92 $\pm$ 8.38	82.34 $\pm$ 7.86
1s Ternary	DepMamba [15]	60.27 $\pm$ 8.64	60.50 $\pm$ 8.56
	Ours	69.19$\pm$ 11.49*	68.31 $\pm$ 11.61*
1s Quinary	DepMamba [15]	59.38 $\pm$ 15.24	56.67 $\pm$ 14.96
	Ours	66.63 $\pm$ 11.36**	64.86 $\pm$ 9.61**
5s Binary	DepMamba [15]	77.67 $\pm$ 8.94	77.07 $\pm$ 8.18
	Ours	85.94 $\pm$ 7.25**	85.23 $\pm$ 7.61**
5s Ternary	DepMamba [15]	55.77 $\pm$ 12.14	54.81 $\pm$ 11.32
	Ours	67.07 $\pm$ 12**	65.31 $\pm$ 11.97**
5s Quinary	DepMamba [15]	55.20 $\pm$ 17.91	50.04 $\pm$ 19
	Ours	68.09 $\pm$ 8.26**	65.95 $\pm$ 7.97**

尽管有这些改进, 我们仍然观察到不同训练运行之间存在不小的差异, 特别是在细粒度 (三元、五元) 任务中。这凸显了数据集固有的可变性所带来的挑战。总体而言, 我们的方法表现出比 DepMamba 相对更好的一致性, 但稳定性仍然是一个值得进一步研究的悬而未决的问题。

4.5消融研究

为了研究模型中每个关键组件的贡献, 我们使用 MPDD-Elderly 数据集对 5 秒五元分类任务进行了消融研究。我们选择这种设置是因为它的难度更高, 分类粒度更细, 可以对每个模块的有效性进行更严格的评估。所有结果均在测试集上进行评估, 并报告为 5 次独立运行的平均值和标准差。结果总结于表 4 中。

表 4: 消融研究结果 (wo =, 无组件)。指标是加权和未加权结果的平均值。

Methods	ACC	F1
<i>Unimodal Feature Extraction</i>		
wo LSTM encoder	60.20 $\pm$ 15.83	57.47 $\pm$ 15.59
wo Dense layer	61.93 $\pm$ 9.88	59.38 $\pm$ 9.00
<i>Bimodal Feature Fusion</i>		
wo BCT	60.20 $\pm$ 8.19	57.53 $\pm$ 10.35
wo Cross-attention	60.13 $\pm$ 15.07	59.01 $\pm$ 12.80
<i>Personalized Feature Fusion</i>		
wo personalized feature	64.17 $\pm$ 10.08	61.50 $\pm$ 9.81
ours	69.33$\pm$8.21	66.91$\pm$7.59

单峰特征提取 如表 4 所示, 用一维卷积层替换 LSTM 编码器会导致性能显著下降, 表明顺序特征提取的有效性

时间特征建模。此外, 删除密集投影层 (通过直接应用最大池化) 也会导致性能下降, 强调了其在融合前转换和增强单峰表示的作用。

双模态特征融合 删除双模态协作变压器 (BCT) 完全导致准确性和 F1 分数显著降低, 证实了其在跨模态集成和对齐中的重要性。此外, 用标准自注意力模块替换 BCT 中的交叉注意力机制会导致性能进一步下降。这些结果强调了显式建模模态间交互以增强多模态对齐的必要性。

个性化特征融合 如表4所示, 删除个性化特征会导致性能适度下降。这表明, 虽然个性化信息不是主导因素, 但它有助于模型更好地适应个体差异, 这在个人背景至关重要的抑郁症检测任务中特别有价值。

4.6 最终结果的呈现

如表5所示, 我们的方法在MPDD-Elderly测试集上排名第一, 最终得分为0.8623, 在所有提交的文章中实现了最高的准确率和有竞争力的F1分数。这一结果凸显了我们方法的有效性。

表 5: MPDD-老年人测试数据集的最终得分。

Team	Score	Accuracy	F1 Score
wakk (ours)	0.8623	0.8613	0.8633
ZBX_LMC	0.8580	0.8519	0.8640
SEU_AIPLab	0.8576	0.8611	0.8541
y61329697	0.8464	0.8446	0.8482

5 结论

本文提出了一个多模态抑郁症检测的统一框架, 旨在增强从预先提取的多模态输入中学习抑郁症相关特征, 并改进跨模态融合。为此, 我们提出了一种双模态协作变压器, 促进模态之间的双向交互, 以及纳入个人特定信息的个性化融合策略。MPDD 基准测试的实验结果表明, 我们的方法实现了最先进的性能, 并在 MPDD-Elderly 赛道中排名第一, 证实了其对于隐私受限的实际应用程序的有效性和实用价值。

6个致谢

这项工作得到了国家自然科学基金项目 (No.6240624、61727809、62222213、U22B2059) 的部分支持。

参考

[1] 毛凯宁, 吴雨绮, 陈杰. 2023.自动化临床抑郁症诊断的系统评价. npj 心理健康研究 2, 1 (2023 年 11 月), 20.doi:10.1038/s44184-023-00040-z

- [2] Wheidima Carneiro de Melo, Eric Granger 和 Abdenour Hadid. 2019. 结合全局和局部卷积 3D 网络从面部表情检测抑郁症。2019年第14届IEEE自动人脸和手势识别国际会议 (FG 2019)。1-8. doi:10.1109/FG.2019.8756568 [3] 杜正银, 李维新, 黄迪, 王云红. 2019. 用注意力时间卷积编码视觉行为以预测抑郁症。2019年第14届IEEE自动人脸和手势识别国际会议 (FG 2019)。1-7. doi:10.1109/FG.2019.8756584 [4] 牛明月, 李明, 付长增. 2024. PointTransform Networks 通过面部关键点自动预测抑郁程度。基于知识的系统 297 (2024), 111951. doi:10.1016/j.knosys.2024.111951 [5] Li Zhou, Zhenyu Liu, Zixuan Shangguan, Xiaoyan Yuan, Yutong Li, Bin Hu. 2023.TAMFN: 用于抑郁症检测的时间感知注意力多模态融合网络。IEEE 神经系统和康复工程汇刊 31 (2023), 669–679. doi:10.1109/TNSRE.2022.3224135 [6] 马星辰, 杨红宇, 陈强, 黄迪, 王云红. 2016.DepAudioNet: 一种基于音频的抑郁分类的高效深度模型。第六届国际视听情感挑战研讨会 (荷兰阿姆斯特丹) (AVEC '16) 的会议记录。计算机协会, 美国纽约州纽约市, 35–42. doi:10.1145/2988257.2988267 [7] 牛明月, 陶建华, 刘斌, 黄健, 廉正. 2023.自动抑郁水平检测的多模态时空表示。IEEE 情感计算汇刊 14, 1 (2023), 294–307. doi: 10.1109/TAFFC. 2020.3031345 [8] 穆罕默德·阿尔·贾扎里和郭东郭. 2021. 通过编码深层时空特征进行基于视频的抑郁水平分析。IEEE 情感计算汇刊 12, 1 (2021), 262–268. doi:10.1109/TAFFC. 2018.2870884 [9] 付长增、付泽林、张琪、匡信和、董家成、苏凯峰、苏益凯、史文博、姚俊峰、赵玉良、赵世奇、王家栋、宋思阳、刘超然、吉川雄一郎、比约恩·舒勒和石黑浩. 2025. 第一个 MPDD 挑战: 多模态人格感知抑郁症检测。arXiv:2505.10034 [cs.AI] <https://arxiv.org/abs/2505.10034> [10] Jeewoo Yoon, Chaewon Kang, Seungbae Kim 和 Jinyoung Han. 2022.D-vlog: 用于抑郁症检测的多模态 Vlog 数据集。AAAI 人工智能会议论文集 36, 11 (2022 年 6 月), 12 226–12234. doi:10.1609/aaai.v36i11.21483 [11] 邵凯、王睿、郝一学、胡龙、陈敏和汉斯·阿诺·雅各布森. 2024.通过多尺度对比进行抑郁识别的多模态生理信号表示学习。第 32 届 ACM 国际多媒体会议论文集 (澳大利亚墨尔本 VIC, 2024 年 10 月 28 日)。ACM, 5692–5701. doi:10.1145/3664647.3681605 [12] 李鑫, 刘海壮, 王荣泉, 邹博超, 林雨欣, 马慧敏. 2024. EMo Transformer: 通过眼动进行基于变压器的抑郁症检测。2024 年 IEEE 国际多媒体会议及博览会 (ICME)。1-6. doi:10.1109/ICME57554.2024.10688241 [13] 张亚洲, 何宇, 陆蓉, 丁一杰. 2022. 使用变压器和双向长期记忆进行抑郁症检测的混合模型。2022 年 IEEE 国际生物信息学和生物医学会议 (BIBM)。2727–2734. doi:10.1109/BIBM55620.2022.9995184 [14] 陶永峰、杨民强、吴玉山、Kevin Lee, Adrienne Kline 和 Bin Hu. 2024.通过时空转换器从视频博客面部和声音流中获得抑郁语义意识。数字通信和网络 10, 3 (2024), 577–585. doi:10.1016/j.dcan.2023.03.007 [15] 叶嘉欣, 张俊平, 单洪明. 2025.DepMamba: 用于多模式抑郁症检测的渐进式融合 Mamba。ICASSP 2025 IEEE 国际声学、语音和信号处理会议 (ICASSP), 印度海得拉巴, 2025 年 4 月 6 日至 11 日。1-5. [16] 宁兆龙, 胡浩, 易凌, 谢子涵, Amr Tolba, 王晓杰. 2024.基于脑电图和语音多模态特征级融合的抑郁症检测辅助决策系统。IEEE 消费电子学报 70, 1 (2024), 3392–3402. doi:10.1109/TCE.2024.3370310 [17] Rahul Gupta, Nikolaos Malandrakis, Bo Xiao, Tanaya Guha, Maarten Van Segbroeck, Matthew Black, Alexandros Potamianos 和 Shrikanth Narayanan. 2014.人机交互中情感维度和抑郁的多模态预测。第四届国际音频/视觉情感挑战研讨会 (美国佛罗里达州奥兰多) (AVEC '14) 论文集。协会
- 计算机, 美国纽约州纽约市, 33–40. doi:10.1145/2661806.2661810 [18] 付长增, 钱凤奎, 苏一凯, 苏凯风, 宋思阳, 牛明月, 施嘉琪, 刘志刚, 刘超然, 石黑俊德, 石黑浩. 2025.面部动作单元指导多模式抑郁症检测的图形表示学习。神经计算 619 (2025), 129106.doi:10.1016/j.neucom. 2024.129106 [19]范慧婷, 张兴楠, 徐莹莹, 方江雄, 张世清, 赵晓明, 于俊. 2024.基于变压器的多模态特征增强网络, 用于集成视频、音频和远程光电体积描记器信号的多模态抑郁症检测。信息融合 104 (2024), 102161. doi:10.1016/j.inffus.2023.102161 [20] 陶永峰, 杨民强, 李惠如, 吴玉山, 胡斌. 2024.DepM-STAT: 用于抑郁症检测的多模态时空注意力变压器。36, 7 (2024 年 7 月), 2956–2966. doi:10.1109/TKDE.2024.3350071 [21] Jonathan Gratch, Ron Artstein, Gale M. Lucas, Giota Stratou, Stefan Scherer, Angela Nazarian, Rachel Wood, Jill Boberg, David De Vault, Stacy Marsella, David R. Traum, Skip Rizzo 和 Louis-Philippe Morency. 2014.人类和计算机访谈的痛苦分析访谈语料库。第九届国际语言资源与评估会议记录, LREC 2014, 冰岛雷克雅未克, 2014 年 5 月 26–31 日, Nicoletta Calzolari, Khalid Choukri, Thierry Declerck, Hrafn Loftsson, Bente Maegaard, Joseph Mariani, Asunción Moreno, Jan Odijk 和 Stelios Piperidis (编辑)。欧洲语言资源协会 (ELRA), 3123–3128. <http://www.lrec-conf.org/proceedings/lrec2014/summaries/508.html> [22] Jyoti Joshi, Roland Goecke, Gordon Parker 和 Michael Breakspear. 2013.身体表情有助于自动抑郁分析吗? 2013 年第 10 届 IEEE 自动人脸和手势识别 (FG) 国际会议和研讨会。1-7. doi:10.1109/FG.2013.6553796 [23] A bhinav Dhall 和 Roland Goecke. 2015.用于抑郁分析的时间分段渔夫向量方法。2015 年情感计算与智能交互国际会议 (ACII)。255–259. doi: 10.1109/ACII.2015. 7344580 [24] Nicholas Cummins, Stefan Scherer, Jarek Krajewski, Sebastian Schnieder, Julien Epps 和 Thomas F. Quatieri. 2015.使用言语分析对抑郁和自杀风险评估进行回顾。言语沟通 71 (2015), 10–49. 土井: 10. 1016/j.specom.2015.03.004 [25] 米歇尔·莫拉莱斯、斯特凡·谢勒和里夫卡·列维坦. 2018.用于多模态抑郁症检测的语言信息融合方法。第五届计算语言学和临床心理学研讨会论文集: 从键盘到临床, Kate Loveys, Kate Niederhoffer, Emily Prud'hommeaux, Rebecca Resnik 和 Philip Resnik (编辑)。计算语言学协会, 路易斯安那州新奥尔良, 13-24. doi:10.18653/v1/W18-0602 [26] Siyang Song, Yiming Luo, Tugba Tumer, Changzeng Fu, Michel Valstar 和 Hatice Gunes. 2024.基于嘈杂面部视频的自动抑郁症识别的损失松弛策略。ACM 翻译。计算。Healthcare 5, 2, 第 12 条 (2024 年 4 月), 24 页. doi:10.1145/3648696 [27] Md Nasir, Arindam Jati, Prashanth Gurunath Shivakumar, Sandeep Nallan Chakravarthula 和 Panayiotis Georgiou. 2016.从语音和面部标志特征进行多模态和多分辨率抑郁症检测。第六届国际视听情感挑战研讨会 (荷兰阿姆斯特丹) (AVEC '16) 的会议记录。计算机协会, 美国纽约州纽约市, 43–50. doi:10.1145/2988257.2988261 [28] 张晓伟, 沉健, Zia ud Din, 刘金勇, 王刚, 胡斌. 2019.多模态抑郁症检测: 使用分类器集成的新策略融合脑电图和副语言行为。IEEE 生物医学和健康信息学杂志 23, 6 (2019), 2265–2275. doi:10.1109/JBHI.2019.2938247 [29] 张兵涛, 蔡汉树, 宋玉波, 陶雷, 李彦林. 2022.基于决策级多模态融合的抑郁症计算机辅助识别。IEEE 生物医学和健康信息学杂志 26, 7 (2022), 3466–3477. 土井: 10. 1109/JBHI.2022.3165640 [30] Michel Valstar, Jonathan Gratch, Björn Schuller, Fabien Ringeval, Denis Lalanne, Mercedes Torres Torres, Stefan Scherer, Giota Stratou, Roddy Cowie 和 Maja Pantic. 2016. AVEC 2016: 抑郁、情绪和情绪识别研讨会和挑战。第六届国际视听情感挑战研讨会 (荷兰阿姆斯特丹) (AVEC '16) 的会议记录。计算机协会, 美国纽约州纽约市, 3-10. 号码: 1 0.1145/2988257.2988258