

HOPE：分层融合优化抑郁症的个性感知估计

Hanlei Shi* Yu Liu*haoxun

Li* Yuxuan Ding* shihanlei23@mails.ucas.ac.cn
liuyu233@mails.ucas.ac.cn lihaoxun23@mails.ucas.ac.cn dingyuxuan23@mails.ucas.ac.cn
中国科学院大学杭州高等研究院 中国浙江省杭州市

胡家喜 hujiayi23@mails.ucas.ac.cn

中国科学院大学杭州高等研究院
中国浙江省杭州市

曲乐元[†] leyuan.qu@ucas.ac.cn

中国科学院大学杭州高等研究院 中国浙江省杭州市

李泰浩[†]

lith@ucas.ac.cn 中国科学院大学
杭州高等研究院 中国浙江省杭州市

抽象的

抑郁症检测仍然受到未能考虑个体异质性的广义建模方法的挑战。为了解决这个问题，多模态人格感知抑郁检测（MPDD）挑战赛将个性化特征引入到建模过程中，旨在更好地捕捉个体差异。然而，基线模型仍然表现出两个关键的局限性：忽略音频中嵌入的文本语义，以及跨任务和样本对同一主题的预测不一致。受这些限制的启发，我们引入了 HOPE（用于优化和个性感知抑郁估计的分层融合），这是一个用于一致的、受试者级别抑郁估计的统一框架。HOPE 首先采用潜在语义投影（LSP）模块，在文本不可用时根据音频特征重建文本语义。然后引入了一种一致性感知集成机制，该机制可以分层融合多分支预测，以解决任务间和样本间的矛盾。HOPE 在 MPDD Challenge Young Track 中获得第一名，展示了

强大的跨模式学习能力和一致的、学科层面的抑郁症预测。

CCS概念

• 计算方法→人工智能。

关键字

抑郁症检测；多模式学习；个性感知建模；层次融合

ACM参考格式：

石汉磊、刘宇、李浩勋、丁宇轩、胡嘉熙、曲乐源和李泰浩。2025.HOPE：分层融合优化抑郁症的个性感知估计。第33届ACM国际多媒体会议（MM’25）会议记录，2025年10月27日至31日，爱尔兰都柏林。ACM，美国纽约州纽约市，7页。<https://doi.org/10.1145/3746027.3762063>

1 简介

抑郁症是一种精神健康障碍，已成为全球主要的公共卫生问题[15, 22]。这种疾病不仅严重损害个人的生活质量和社会功能，而且还对其身体健康、家庭关系和职业发展构成长期风险[16, 19]。传统上，抑郁症评估方法主要依赖于心理测量量表[1, 8]和应用于结构化数据的浅层学习算法[4, 21]。近年来，深度学习的快速发展为抑郁症检测开辟了新的方向，特别是通过整合语音、面部表情和文本数据信息的多模态方法[2, 6, 24]。

然而，大多数现有方法仍然采用广义的建模范式，这往往无法解释个体之间抑郁症的异质性[13, 18]。例如，即使抑郁症严重程度相同，性格不同的人

*These authors contributed equally to this work.

Hanlei Shi: Designed and implemented the modified multi-branch architecture, with specialized integration of the LSP module. **Yu Liu:** Developed the consistency-aware subject-level fusion strategy; led the writing and completed final code integration and open-source release preparation. **Haoxun Li:** Proposed and implemented the LSP module, including its architecture design, feature alignment strategy, and supervised training pipeline. **Yuxuan Ding:** Procured and preprocessed MER datasets; conducted component-wise analysis attributing gains to innovations. Author order was randomized to reflect equal contribution.

[†]Corresponding author.



This work is licensed under a Creative Commons Attribution 4.0 International License. MM’25, Dublin, Ireland

© 2025 Copyright held by the owner/author(s).

ACM ISBN 979-8-4007-2035-2/2025/10

<https://doi.org/10.1145/3746027.3762063>




图 1: HOPE 概述。我们首先使用 LSP 模块从音频中提取相应的文本语义特征。第一阶段，将四种模态特征（视频、音频、个性化文本、伪文本特征）输入到分支模型中进行初步融合，以增强各个分支的能力。第二阶段根据第一阶段的分支模型输出进行样本混淆，然后进行二次特征融合。该系统最终通过双分类器架构生成二元和三元分类结果。

特征可能会在言语韵律、面部线索或语言风格中表现出不同的模式[23]。由于个体差异，当前的抑郁症检测模型表现有限[3, 7, 14]。

为了强调这些局限性，ACM Multimedia 2025 MPDD 挑战赛 [5] 引入了基于预先提取的多模态特征的基准任务。虽然基线 MPDD 模型已经验证了人格特质在抑郁症建模中的关键作用，并证明纳入人格信息可以显著提高预测准确性，但仍然存在两个关键局限性。首先，基线模型忽略了音频传达的文本语义内容（即受试者的实际言语表达），这通常包含识别抑郁倾向的关键临床线索。其次，在 MPDD 数据集中，每个主题都与三个不同的样本相关联，每个样本在两个窗口长度（1 秒和 5 秒）和两个分类任务（二元和三元）下进行评估。在基线设置中，这些被视为独立实例，而不考虑受试者身份。因此，现有方法经常会在样本、窗口长度和同一个体的任务上产生不一致和矛盾的临床预测。

为了解决这些局限性，我们提出了 HOPE——用于优化和个性感知抑郁估计的分层融合，这是一个为一致性感知、受试者级抑郁预测量身定制的统一框架。本研究的创新点如下：首先，受到视听对话中的文本信息可以提供更丰富的文本语义特征的观察的启发[17, 19]，我们构建了一个新的 LSP 模块，该模块训练于

广泛的外部数据集。在原始对话脚本不可用且原始视听数据的访问受到限制的情况下，该模块根据音频特征重建文本语义表示，有效补充基于文本的关键语义信息。其次，为了解决在 MPDD 基线中观察到的主题级预测不一致问题，我们设计了一种一致性感知的个体级集成机制。通过分层融合来自多个特定于任务和特定于样本的分支的输出，该模型学习解决逻辑矛盾并放大最可靠的信号，确保连贯且临床上合理的主题级预测。这项研究的主要贡献可概括如下：

- 我们提出了 LSP 模块，当原始对话文本数据和视听数据无法访问时，它从音频特征中提取转录级语义信息，从而补充音频携带的基于文本的关键语义信息。
- 我们提出了一种一致性意识的个体层面的整合机制，该机制可以分层融合多分支预测，以解决 MPDD 基线中任务间和样本间的矛盾，从而提高抑郁症评估的受试者层面的可靠性。
- 我们提出的 HOPE 框架在 MPDD-Young 竞赛赛道上获得了第一名，在严格的隐私约束（仅允许预先提取的特征）和有限的训练样本下展示了卓越的跨模态学习能力。

2 方法

2.1 方法概述

为了解决基线的两个局限性，即忽略音频的文本语义（包含临床重要的言语表达）以及通过独立处理同一受试者样本而产生不一致的判断，我们提出了 HOPE。如图1所示，其框架包含LSP模块和一致性感知的个体级集成机制，专门解决这些问题。

文本模态为抑郁症检测提供了比视听数据更丰富的临床线索[17, 19]，受到这一证据的启发，我们在辅助 MER2025 数据集 [10] 上训练 LSP 模块，以建立从音频到文本特征的端到端映射，从而无需语音转录即可直接进行语义提取 [9]。由此产生的“伪文本特征”作为一种新的模式并入我们的框架中，技术实现详见第 2.2 节。

在保留 MPDD 挑战定义的四分支子任务结构的同时，HOPE 建立在基线设计的基础上，其中针对每个窗口长度（1s、5s）和任务类型（二元、三元）使用单独的特征提取器，形成四个不同的分支。每个受试者总共贡献 12 个输入——两个窗口长度和两个任务设置下的三个样本。然而，基线独立地处理这些输入，通常会在同一主题的任务和时间窗口之间产生相互冲突的预测。为了解决这个问题，我们引入了一个两阶段的层次融合机制，以促进主题级别的一致性。样本输出首先通过学习注意力聚合到任务级嵌入中，然后通过时间推理模块进行整合，该模块可以协调分支之间的差异。这使得模型能够选择性地放大可靠的预测，在受试者层面产生连贯且具有临床意义的结果。进一步的技术细节在第 2.3 节和第 2.4 节中详细阐述。

2.2 潜在语义投射模块

除了利用静态人格特征之外，HOPE 还引入了源自受试者口语音频的动态语义表示。这种表示的目的是编码高级语言意义——补充所说的内容（内容）和由谁（个性）组成。目标是将每个音频片段投影到与句子级语言模型一致的语义空间中，从而更深入地理解与抑郁症相关的内容。

由于 MPDD 中的隐私保护限制，只有预先提取的 Wav2Vec [20] 特征可用，而不是原始音频数据。为了从这些有限的音频特征中提取更丰富的语义表示，从而更好地捕获文本内容，如图 2 所示，我们设计了一种池化映射方法，将可用的 512 维音频特征转换为 1024 维的文本对齐语义空间。

我们的方法在算法 1 中得到了形式化，采用了一种简化的训练策略，在训练期间将整个话语视为一个单元，同时在推理期间逐段应用学习到的映射。具体来说，在训练阶段，我们对每个话语中的完整 Wav2Vec 特征序列进行平均池化，以生成全局 512 维表示。然后通过中间维度为 1024 的三层前馈网络 f_θ 处理该池化特征，并结合 ReLU 激活，




图 2：特征映射过程图示。LSP模块将音频特征转换为相应的文本语义特征。虚拟数据流表示原始音频数据可用时的处理管道，而真实数据流表示仅使用音频特征的场景。

Algorithm 1 Pseudo Code of LSP Module

Input: Training pairs $\{(a_i, t_i)\}$, where $a_i \in \mathbb{R}^{512}$, $t_i \in \mathbb{R}^{1024}$, MPDD audio feature $A_{comp} \in \mathbb{R}^{T \times 512}$ (5-second).
Output: Semantic sequence $T_{semantic} \in \mathbb{R}^{T \times 1024}$
Training Phase:
repeat
 Sample (a, t) from training set
 $t_{pred} \leftarrow f_\theta(a)$
 $L \leftarrow 1 - \cos(t_{pred}, t)$
 $\theta \leftarrow \theta - \alpha \nabla_\theta L$
until convergence
Inference Phase (MPDD Data):
 $T_{semantic} \leftarrow []$
for $j = 1$ **to** T **do**
 $t_j \leftarrow f_\theta(A_{comp}[j])$
 $T_{semantic}.append(t_j)$
end for
return $T_{semantic} \in \mathbb{R}^{T \times 1024}$

dropout ($p = 0.2$) 和层归一化。该网络使用余弦相似性损失进行训练，以最小化预测特征和真实 RoBERTa [12] 句子嵌入之间的语义距离。

在推理时，我们将经过训练的映射网络 f_θ 独立应用于 MPDD 数据的每个 5 秒音频片段。如算法 1 中详述，给定形状为 $(T, 512)$ 的分段级输入特征，其中每个分段对应于 5 秒的音频块，我们的模型输出一系列语义向量

形状为 $(T, 1024)$ 。每个输出向量捕获相应音频片段的潜在语义，创建时间对齐的语义表示，保留原始音频的时间结构和相应文本内容的语义丰富性。

这些生成的伪文本特征在交叉注意力[11]机制中提供键和值，而个性化文本充当查询。这种交互使模型能够将受试者所表达的内容与他们的身份保持一致，从而鼓励提取高度个性化的、与抑郁症相关的线索。这种注意力机制专门在分段级别上运行，产生个性条件表示，作为后续分层融合模块的固定输入。

重要的是，生成的伪文本特征被视为附加的文本对齐模式，与原始音频特征正交，并无缝集成到多模态融合过程中。第3节中的经验结果证实，这种设计可以提高二元和三元设置中的辨别力。

2.3 一致性感知的个体级特征集成

基于 MPDD 基线，我们的 HOPE 框架中的四个分支中的每一个都对应于不同的时间分辨率和分类任务。为了在挑战的严格输入限制下提高特征质量，我们引入了三个轻量级且有效的修改：(i) 用于捕获本地视听模式的卷积层，(ii) 用于音频和视觉特征之间跨模态对齐的Q-Former模块，以及 (iii) 将特定于主题的先验注入样本级表示的个性感知注意机制。

这些丰富的嵌入用于通过两阶段融合策略为每个主题导出稳定且一致的表示，该策略以 $12 \rightarrow 3 \rightarrow 1$ 模式集成跨子任务和时间样本的特征。这种分层集成使模型能够将异构线索整合为连贯的个体级语义表示。与假设特征兼容性的传统基于注意力的融合不同，我们的方法将范式从特征聚合转变为冲突仲裁，通过个性感知解决方案明确解决跨任务预测冲突。

在第一阶段，我们聚合来自四个不同模态特定分支（音频、视频、个性化文本和伪文本）的信息，每个分支都由二元/三元分支模型中相应的子网络处理（见图1）。这些子网络将各自的输入转换为中间表示，表示为 $f_{branch}^{(i)}$ 。为了实现有效的融合，每个特定于分支的特征向量被线性变换到共享的潜在空间：

$$f_{aligned}^{(i)} = \text{Linear}_i(f_{branch}^{(i)}) \in \mathbb{R}^{512}, \quad i \in \{1, 2, 3, 4\} \quad (1)$$

对齐的向量被堆叠成形状为 4×512 的张量，并通过多头注意力（MHA）模块来建模分支间依赖关系：

$$F_{attn} = \text{MHA}(F_{stacked}, F_{stacked}, F_{stacked}) \quad (2)$$

其中 $F_{stacked}$ = 堆栈($[f_{aligned}^{(1)}, \dots, f_{aligned}^{(4)}]$)。注意力层的输出在分支之间进行平均，并使用具有残差连接和层归一化的两层MLP进行增强：

$$f_{fused} = \text{LayerNorm}(\text{MLP}(\text{mean}(F_{attn}))) \in \mathbb{R}^{512} \quad (3)$$

该融合向量在给定时间步捕获一致的子任务级嵌入，跨时间尺度和分类粒度组合信号。

融合的第二阶段整合三个输入窗口的时间信息。如图1所示，我们获得了对应于每个受试者的不同样本的三个融合向量 $f_{fused}^{(1)}, f_{fused}^{(2)}, f_{fused}^{(3)}$ 。这些被输入 BiLSTM 来编码时间依赖性：

$$H_{temporal} = \text{BiLSTM}([f_{fused}^{(1)}, f_{fused}^{(2)}, f_{fused}^{(3)}]) \in \mathbb{R}^{3 \times 512} \quad (4)$$

我们在时间输出上应用另一个 MHA 层来捕获样本之间不同的重要性：

$$H_{attn}, W_{attn} = \text{MHA}(H_{temporal}, H_{temporal}, H_{temporal}) \quad (5)$$

注意力权重在头部之间取平均值，并使用 softmax 函数进行归一化，以计算时间重要性分布：

$$w_{temporal} = \text{SoftMax}(\text{mean}(W_{attn}, \text{dim} = 1)) \quad (6)$$

最后，计算所关注的时间特征的加权和，然后通过 MLP 生成最终的主题级表示：

$$f_{final} = \text{MLP}\left(\sum_{t=1}^3 w_{temporal}^{(t)} \cdot H_{attn}^{(t)}\right) \in \mathbb{R}^{512} \quad (7)$$

生成的向量 f_{final} 编码语义丰富、时间感知且个性一致的信息。它作为下游多任务分类的输入，使每个主题能够进行连贯的二元和三元预测。

2.4 多任务分类

为了支持细致入微的抑郁症评估，HOPE 采用多任务学习策略，同时预测二元（健康与抑郁）和三元（健康与轻度与重度）标签。这种公式鼓励模型学习捕获核心抑郁信号的共享表示，同时允许特定任务的分类器关注不同的严重程度粒度。

两个分类头都对相同的最终特征向量 $f_{final} \in \mathbb{R}^{512}$ 进行操作，该向量对个性感知、时间集成和多模态对齐信息进行编码。我们对两个头采用与 MPDD 基线中使用的相同的全连接分类架构。二元分类器 C_{binary} 输出两个类别的 logits，而三元分类器 $C_{ternary}$ 生成三个严重级别的 logits。给定共享特征输入 $h_{shared} = f_{final}$ ，预测分布为：

$$P(y_{binary}) = \text{SoftMax}(C_{binary}(h_{shared})) \quad (8)$$

$$P(y_{ternary}) = \text{SoftMax}(C_{ternary}(h_{shared})) \quad (9)$$

总体训练目标是二元和三元交叉熵损失的加权组合：

$$\mathcal{L}_{total} = \alpha_b \cdot \mathcal{L}_{binary} + (1 - \alpha_b) \cdot \mathcal{L}_{ternary} \quad (10)$$

其中 α_b 是二元任务权重因子。我们凭经验设置 $\alpha_b = 0.5$ ，这在验证集上的两个任务中产生了最佳的整体性能。这种平衡的权重确保两个任务都不会主导学习过程，从而促进有效的表征共享和相互强化。两种损失都是使用标准分类交叉熵计算的：

$$\mathcal{L}_{binary} = - \sum_{i=1}^N y_i^{binary} \log P(y_i^{binary}), \quad (11)$$

$$\mathcal{L}_{ternary} = - \sum_{i=1}^N y_i^{ternary} \log P(y_i^{ternary}) \quad (12)$$

3 实验

3.1 数据集和指标

LSP 模块数据集和指标。为了训练和评估所提出的 LSP 模块，我们利用 MER2025 数据集——一个为现实中文媒体内容中的情感识别而开发的大型多模态数据集 [10]。完整数据集包含超过 180,000 个话语，每个话语都带有相应的情感标签进行注释，并在音频、文本和视频模式之间进行对齐。出于我们的目的，我们专门关注配对的音频文本样本，选择 100,000 个话语来训练 LSP 模块。它们按照 7:1.5:1.5 的比例分为训练集、验证集和测试集。为了评估投影伪文本特征的质量，我们采用均方根误差（RMSE）和余弦相似度（Cosine Sim）作为补充指标。

完整的模型数据集和指标。我们在 MPDD-Young 数据集 [5] 上评估我们的完整模型，这是一个专为年轻人抑郁症检测而设计的多模态数据集。该数据集提供同步的音频、视觉和人口统计数据，以及基于 PHQ-9 的抑郁症严重程度标签和基于 BigFive-10 量表的个性属性。每个样本都进一步丰富了性别、年龄和出生地区元数据，以支持更细致的分析。组织者为每个参与者提供预先提取的多模式特征，而不是原始音频或视频。每个人的每种模式都有三个数据样本（表示为 _1、_2、_3）。我们实验中使用的音频、视觉和个性化语义特征遵循 MPDD-Young 数据集 [5] 中提供的配置。

按照基线评估协议，我们采用四个指标：加权和未加权的 F1 分数（ W_{F1} / U_{F1} ）以及加权和未加权的准确度（ W_{Acc} / U_{Acc} ）。最终分数计算为四项任务的 F1 分数和准确度的加权平均值。

在我们的评估中，上述方程中的每个任务 i 对应于数据集支持的特定分类设置。MPDD-Young 数据集定义了两个任务：

(1) 正常和抑郁之间的二元分类，以及 (2) 正常、轻度抑郁和严重抑郁之间的三元分类。对这些任务的表现指标进行平均，以计算最终的赛道分数。

3.2 实验设置

LSP 模块实验设置。我们比较了从音频输入生成伪文本特征的两策略，区分

表1：不同映射模型的LSP结果

Model	Text encoder	Cosine Sim ↑	RMSE ↓
Map1	Bert	87.85	51.50
	RoBERTa	95.63	33.82
Map2	Bert	87.84	46.62
	RoBERTa	95.63	25.46

主要是通过其产出的结构。第一种方法为每个话语生成一个 1024 维向量，而第二种方法（我们采用的策略）生成形状为 $(T, 1024)$ 的向量序列，其中 T 表示话语中 5 秒片段的数量。

在第一个名为 Map1 的方法中，每个话语被分为 5 秒的块，从中提取 512 维 Wav2Vec2 特征并将其堆叠成形状为 $(T, 512)$ 的序列。然后，该序列通过前置有 $[cls]$ 标记的 Transformer 编码器，并且训练与 $[cls]$ 对应的输出以回归完整转录的 RoBERTa 嵌入。相比之下，我们的方法使用经过训练的映射网络（我们称之为 Map2）独立处理每个 5 秒片段，生成形状为 $(T, 1024)$ 的片段级语义嵌入序列。这种设计保留了预先提取的音频特征中固有的时间动态，并能够随着时间的推移捕获细粒度的语义线索。这种表示本质上与我们跨时间和模式运行的分层融合机制兼容。

完整的模型实验设置。我们的完整模型的实验采用两阶段训练策略：（1）第一阶段侧重于训练每个分支模型，使其专门针对其特定输入类型（由样本、窗口长度和分类任务的特定组合定义）进行抑郁症检测，从而增强特定于任务的性能；

（2）第二阶段建立在第一阶段训练的分支模型的基础上，采用分层融合机制，集成跨分支和时间样本的特定于任务的特征。

第一阶段采用遵循基线配置的10倍交叉验证策略，其中四个特定于任务的分支中的每一个都使用与原始设置一致的参数单独进行训练。第二阶段继承了第一阶段的整体配置——包括数据加载策略和随机种子设置——并使用性能最佳的折叠权重进行 100 个 epoch 的训练。对于所有实验，我们使用批量大小 8 并固定随机种子。数据集按主题 ID 分割，以防止训练和验证之间的身份泄露。该网络采用 ReLU 激活，分类器层的丢弃率为 0.3。使用 Adam 进行优化（学习率 = 0.001、 $\beta_1 = 0.9$ 、权重衰减 = $1e-4$ ），并且当验证准确性停滞时，基于平台的调度程序会降低学习率。所有模型均在 PyTorch 2.3.0 中实现，并在 8×L20 GPU 上进行训练。

3.3 实验结果

特征映射比较。如表 1 所示，RoBERTa 在两种映射策略上始终优于 BERT，这表明它更适合我们的语义投影任务。两个都

表 2: 使用 1 秒和 5 秒窗口输入的验证集结果。符号 *、† 和 ‡ 表示相应的模型基于表中前一组的最佳性能配置构建由浅蓝色行突出显示)。

在 (作为

Model	1s/5s Binary				1s/5s Ternary			
	U_{F_1}	W_{F_1}	$U_{Acc.}$	$W_{Acc.}$	U_{F_1}	W_{F_1}	$U_{Acc.}$	$W_{Acc.}$
Baseline	49.77/54.64	49.77/54.64	50.00/54.92	50.00/54.92	35.05/45.75	41.60/54.64	41.60/54.65	34.85/46.09
Baseline + GRU	60.10/60.59	60.10/60.59	60.23/60.61	60.23/60.61	38.77/44.81	45.99/53.51	45.83/53.41	38.67/45.04
Baseline + CNN	68.18/67.04	68.18/67.04	68.18/67.05	68.18/67.05	45.48/44.75	53.07/51.02	52.57/51.14	46.34/45.30
* + Mix up	74.88/74.99	74.88/74.99	75.00/75.00	75.00/75.00	51.95/58.56	58.74/64.46	57.95/64.77	51.55/57.23
* + SMOTE	54.52/59.42	54.52/59.42	54.55/59.47	54.55/59.47	35.05/45.75	41.60/54.64	41.67/54.55	34.85/46.09
* + Class-weighted	70.44/71.56	70.44/71.56	70.45/71.59	70.45/71.59	49.27/52.55	55.77/59.38	55.68/59.09	49.46/52.59
* + Border-SMOTE	78.34/78.34	78.34/78.34	78.41/78.41	78.41/78.41	59.35/58.21	64.35/64.93	63.64/64.77	59.66/57.23
* + Mix up+SMOTE	65.86/63.47	65.86/63.47	65.91/63.64	65.91/63.64	42.00/42.13	47.32/50.14	47.73/50.00	40.32/42.20
* + Mix up+Border-SMOTE	75.98/73.86	75.98/73.86	76.14/73.86	76.14/73.86	52.95/55.70	59.96/61.22	59.09/61.36	52.59/54.10
* + Mix up+Class-weighted	69.31/68.16	69.31/68.18	69.32/68.18	69.32/68.18	45.96/49.27	55.42/55.77	55.68/55.68	45.99/49.46
† + Concat	77.17/76.06	77.17/76.06	77.27/76.14	77.27/76.14	57.46/63.39	63.90/66.35	63.64/65.91	56.47/62.03
† + Q-former	81.73/82.95	81.73/82.95	81.82/82.95	81.82/82.95	71.68/67.44	75.44/72.51	76.14/72.73	76.14/66.57
‡ + Map1 BERT Concat	80.66/82.90	80.66/82.90	80.68/82.95	80.68/82.95	62.24/72.69	67.44/76.62	67.05/77.27	62.22/77.27
‡ + Map1 RoBERTa + Concat	86.36/86.36	86.36/86.36	86.36/86.36	86.36/86.36	80.91/78.97	81.72/80.57	81.82/80.68	81.82/80.68
‡ + Map2 RoBERTa + Concat	88.63/92.04	88.63/92.04	88.64/92.05	88.64/92.05	82.75/76.00	82.83/81.64	82.95/81.82	82.95/75.51
‡ + Map2 RoBERTa + Q-former	91.64/95.45	91.64/95.45	91.67/95.45	91.67/95.45	85.05/78.77	85.71/85.12	85.98/85.23	85.98/78.35
‡ + Map2 RoBERTa + Cross-Att	96.21/97.73	96.21/97.73	96.21/97.73	96.21/97.73	86.09/80.71	86.93/87.53	87.12/87.50	87.12/80.43

当使用相同的文本编码器时，方法获得了可比较的余弦相似度分数，这表明语义方向性通常得到了很好的保留。然而，我们的方法在 RoBERTa 监督下产生了明显较低的 RMSE，突出了其在保持语义特征的数值保真度方面的优势。

我们创新性地设计了两种音频文本特征映射架构，并将生成的特征应用到最佳的第一阶段模型中进行比较验证。表 1 中的实验数据清楚地表明，新颖的特征映射方法表现出有竞争力的性能。LSP 模块的最终实现是根据表1和表2所示的结果记录到“Map2 RoBERTa”设置。

分支模型结果。(1) 为了捕获本地视听模式，我们使用额外的 CNN 或 GRU 层增强了基线的 LSTM 特征提取。如表 2 所示，结果表明 CNN 层显著提高了局部模式识别能力。(2) 为了解决数据集中的类别不平衡和小样本问题，我们实现了多种数据增强方法。表 2 显示了 Border-SMOTE 策略取得的最佳性能。

(3)为了更好地在分支模型中进行多模态融合，我们引入了Q-former融合方法。表2中的“† + Q-former”结果验证了其有效性。(4) 为了进一步增强分支模型的性能，我们开发了个性感知音频地图文本特征。通过模态映射模型训练获得不同的音频-地图-文本特征后，测试了各种文本特征融合方法。如表 2 所示，“‡ + Map2 RoBERTa + Cross-Att”组合提供了最佳性能。这里，“Map2 RoBERTa”表示通过训练相应的LSP模型获得的伪文本特征，“Cross-Att”表示伪文本特征和个性化文本特征之间的交叉注意力融合方法。

表 3: 测试集的最终结果

Training Stage	Final Score	Final F1	Final Acc.
Stage One	85.39	85.43	85.35
Stage Two	94.51	94.27	94.76

具有一致性意识的个体级特征集成结果。在第二阶段，我们基于第一阶段分支模型引入了分层融合机制，以跨分支和时间样本集成特定于任务的特征。如表3所示，这个两阶段框架显著提高了性能：最终F1从85.43%增加到94.27%（+8.84），准确性从85.35%增加到94.76%（+9.41），最终得分从85.39%增加到94.51%。这些结果验证了所提出的两阶段训练框架内分层融合机制的有效性。

4结论

在这项工作中，我们提出了 HOPE，一种用于抑郁症评估的新颖的分层多模态框架，它明确地结合了个性感知表示和主题级一致性建模。通过引入 LSP 模块，HOPE 有效地弥合了隐私受限设置下音频特征和文本表示之间的语义差距。分层融合策略将异构模式和样本级预测集成到一致的主题级输出中。HOPE 在 ACM MM 2025 MPDD Challenge (Young Track) 中获得第一名，展示了出色的表现。我们的研究结果强调了在多模式情感计算中建模个性化行为的重要性，并为未来基于个性的心理健康评估工作开辟了道路。

致谢

该工作得到了浙江省重点研发计划（2025C01104）、杭州高等研究院科研启动基金（2024HIASC2001）和浙江省自然科学基金（No. LQN25F020001）的资助。

参考

[1] 亚伦·T·贝克、罗伯特·A·斯蒂尔和格雷戈里·K·布朗。1996. 贝克抑郁量表-II。心理评估 7, 3 (1996), 490–498. [2] 陈自强、王丹丹、楼亮亮、张世清、赵晓明、蒋树强、于军、肖军。2025. 通过跨模态特征重建和分解进行文本引导的多模态抑郁症检测。信息融合 117 (2025), 102861. [3] Jiaee Cheong, Aditya Bangar, Sinan Kalkan 和 Hatice Gunes。2025. U-Fair: 基于不确定性的多模态多任务学习，实现更公平的抑郁症检测。健康机器学习论文集 (PMLR) 259 (2025), 1–14. [4] Munmun De Choudhury, Michael Gamon, Scott Counts 和 Eric Horvitz。2013. 通过社交媒体预测抑郁症。在 ICWSM 的会议记录中。128–137. [5] 付长增、付泽林、张琪、匡新和、董家成、苏凯峰、苏益凯、史文波、姚俊峰、赵玉良、赵世奇、王家栋、宋思阳、刘超然、吉川雄一郎、Björn Schuller、Hiroshi Ishiguro。2025. 第一个 MPDD 挑战：多模态人格感知抑郁症检测。arXiv:2505.10034 [cs.AI] <https://arxiv.org/abs/2505.10034> [6] Md Rafiqul Islam, Muhammad Ashad Kabir, Ashir Ahmed, Abu Raihan M Kamal, Hua Wang 和 Anwaar Ulhaq。2018. 使用机器学习技术从社交网络数据中检测抑郁症。健康信息科学与系统 6 (2018), 1-12. [7] 吉喆，余东杰，王宝勋。2021. 通过半监督深度学习进行人格感知抑郁症检测。信息处理与管理 58, 3 (2021), 102539. [8] Kurt Kroenke, Robert L Spitzer 和 Janet BW Williams。2001. PHQ-9: 简短的抑郁症严重程度测量的有效性。普通内科杂志 16, 9 (2001), 606–613. [9] 李云浩，张曦，黄金涛。2023. 跨模态抑郁症检测：通过对比学习调整声学 and 语义表示。信息融合 92 (2023), 102784. [10] 连正，刘锐，徐克乐，刘斌，刘雪飞，张亚洲，刘鑫，李勇，程泽邦，左浩林，马紫阳，彭晓江，陈谢，李亚，Erik Cambria，赵国英，Björn W. Schuller，陶建华。2025. MER 2025: 何时

情感计算与大型语言模型的结合。arXiv:2504.19423 [cs.HC] <https://arxiv.org/abs/2504.19423> [11] Hezheng Lin, Xing Cheng, Xiangyu Wu, Fan Yang, Dong Shen, Zhongyuan Wang, Qing Song 和 Wei Yuan。2021. CAT: 视觉变压器中的交叉注意力。arXiv:2106.05786 [cs.CV] <https://arxiv.org/abs/2106.05786> [12] Yinhuan Liu, Mylène Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer 和 Veselin Stoyanov。2019. Roberta: 一种稳健优化的 bert 预训练方法。arXiv 预印本 arXiv: 1907.11692 (2019). [13] 马俊文，张悦，李文杰，赵通。2023. 个体化抑郁症检测：挑战和未来方向。IEE E 情感计算汇刊 (2023). doi:10.1109/TAFFC.2023.3278541 抢先体验。[14] 米歇尔·R·莫拉莱斯、斯特凡·舍勒和里夫卡·列维坦。2018. 从言语检测抑郁症的跨文化研究：原型模型与个性化模型。在《Interspeech 会议录》中。1215–1219. [15] Saba Moussavi, Somnath Chatterji, Emese Verdes, Ajay Tandon, Vikram Patel 和 Bedirhan Ustun。2007 年。抑郁症、慢性病和健康状况下降：世界健康调查结果。柳叶刀 (2007)。[16] 世界卫生组织等。2017. 抑郁症和其他常见精神障碍：全球健康估计。(2017)。[17] Anupama Ray, Siddharth Kumar, Rutvik Reddy, Prerana Mukherjee 和 Ritu Garg。2019. 使用文本、音频和视频进行抑郁症预测的多级注意力网络。第九届国际视听情感挑战与研讨会论文集。81–88. [18] E. Ryumina, M. Pechenizkiy 和 V. Petrushin。2023. 多模态人格特质评估 (MuPTA) 语料库。Interspeech 论文集 (2023), 341–345. [19] Misha Sadeghi, Robert Richer, Bernhard Egger, Lena Schindler-Gmelch, Lydia Helene Rupp, Farnaz Rahimi, Matthias Berking 和 Bjoern M Eskofier。2024. 利用大语言模型和面部表情的多模态方法进行抑郁症检测。npj 心理健康研究 3, 1 (2024), 66。[20] Steffen Schneider, Alexei Baevski, Ronan Collobert 和 Michael Auli。2019. wav2vec: 语音识别的无监督预训练。arXiv 预印本 arXiv:1904.05862 (2019). [21] Adrian B R Shatte, David M Hutchinson 和 Samantha J Teague。2019. 心理健康中的机器学习：方法和应用的范围界定审查。心理医学 49, 9 (2019), 1426–1448. [22] 金融时报。2024 年。最大的问题是：是什么导致了全球心理健康危机？英国《金融时报》(2024 年)。 <https://www.ft.com/...> [23] Michael Trotzek, Sebastian Koitka 和 Christoph M Friedrich。2020. 使用无监督域适应的跨语料库抑郁症检测。专家系统及其应用 161 (2020), 113666. [24] 徐振策，高远，王芳，张龙前，张力，王俊科，舒杰。2025. 基于语音和文本多模态融合的抑郁症检测方法。科学报告 15 (2025 年 7 月)。doi:10.1038/s41598-025-03524-4