

基于自适应时间窗选择的多级分段融合多模态人格感知老年抑郁症检测

刘玉云 东南大
学生物科学与医学工
程学院 中国南京 liuyu
yun@seu.edu.cn

张凯飞 东南大学
生物科学与医学工程
学院 中国南京 220242
613@seu.edu.cn

马英豪 东南大学
生物科学与医学工程
学院 中国南京 220242
615@seu.edu.cn

徐晓林 东南大学生物科学与医学工程学院
中国南京 xuxiaoolin@seu.edu.cn 东南大学生物科学与医学
工程学院 南京中国 qitianh
ua@seu.edu.cn

郑文明
东南大学儿童发展与学习科学教育
部重点实验室 中国南京 weming_zh
eng@seu.edu.cn

程陆* 东南大学
生物科学与医学工程
学院 中国南京 Cheng.
lu@seu.edu.cn

袁纵*东南大学
生物科学与医学工程
学院, 南京, 中国 xh
zongyuan@seu.edu.cn

抽象的

重度抑郁症 (MDD) 是一种普遍且严重的精神疾病, 由于其症状的复杂性和变异性, 其检测仍然具有挑战性。传统的单模态方法往往无法捕捉到抑郁线索的全部谱系, 这导致了多模态方法的兴起。ACM Multimedia 2025 “多模态人格感知抑郁症检测挑战赛” (MPDD 2025) 旨在通过整合多模态数据来推进更准确的抑郁症检测模型的开发。在本文中, 我们提出了一种针对 MPDD-Elderly Track 的基于自适应时间窗口选择的多级分段融合 (MSF-ATS) 方法。为了解决稀疏和短暂的抑郁症状的挑战, 我们融合分段级别的分类以获得主题级别的分类。采用基于平均类别方差的自适应时间窗口选择来选择方差最小的窗口以获得更稳定的检测结果。我们的方法在 MPDD 2025 上取得了 0.8576 的平均分数

官方测试集, 显著优于基线分数 0.6675。

CCS概念

• 计算方法 → 人工智能;
用计算→健康信息学;
• 信息系统 → 多媒体信息系统。

关键字

抑郁检测、多模态融合、主题级别分类、时间窗口选择

ACM参考格式:

刘雨云、张凯飞、马英豪、徐晓林、齐天华、郑文明、路成和宗袁。
2025.基于自适应时间窗口选择的多级分段融合用于多模态人格感知老年抑郁症检测。第 33 届 ACM 国际多媒体会议 (MM ' 25) 会议记录, 2025 年 10 月 27 日至 31 日, 爱尔兰都柏林。ACM, 美国纽约州纽约市, 7 页。https://doi.org/10.1145/3746027.3762064

*Corresponding Authors

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
MM '25, Dublin, Ireland

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 979-8-4007-2035-2/2025/10
https://doi.org/10.1145/3746027.3762064

1 简介

重度抑郁症 (MDD) 是全世界最常见和最致命的精神疾病之一, 影响着各个年龄段的数亿人[10]。确定一个人是否患有抑郁症并评估其严重程度可以有效控制病情并防止进一步恶化。然而, 由于与 MDD 相关的症状的复杂性和多样性, 传统的单一模式方法通常难以捕获全方位的抑郁线索 [3, 4]。这一限制导致了

人们对抑郁症检测的多模式方法越来越感兴趣。通过整合音频、视觉和文本信息等多个数据源，多模态抑郁检测模型捕获更广泛的抑郁线索，从而提高抑郁检测任务的整体性能[2,16,23]。

为了加速多模态抑郁症检测方法的临床转化，ACM Multimedia 2025组织了“多模态人格感知抑郁症检测挑战赛”（MPDD 2025）[7]。本次竞赛创新性地引入了人格认知的维度，为每个参赛者提供了包括人口统计属性和大五人格特征在内的结构化身份信息，填补了以往数据库中缺失此类数据的空白。该竞赛包括两个子赛道：MPDD-老年赛道，其针对老年人群，其数据来自真实的临床访谈记录；MPDD-青年赛道，其重点针对年轻受试者，其数据来自阅读任务和自我报告的问卷。该竞赛旨在鼓励研究人员开发更准确的多模式抑郁症检测模型。

在自动抑郁症检测过程中，如何将数据适当地分割成时间窗口是一个关键挑战。研究表明，数据段的选择直接影响抑郁检测模型的性能[15]。一些研究支持使用较短的片段来捕捉抑郁信号的微妙和快速变化[21]。然而，短片段更容易受到噪声干扰，可能导致模型过度拟合不相关信息，从而影响检测性能。相反，较长的片段提供更多的上下文信息，有助于增强模型的稳定性并降低对短暂噪声的敏感性[5]。然而，较长的时间窗口也有局限性，因为它们可能会掩盖一些短暂但重要的抑郁信号。这反映了粒度和鲁棒性之间的权衡。如何合理选择数据的时间窗口仍然是当前抑郁症检测的重大挑战。此外，临床访谈中的抑郁症状通常不会在整个访谈中始终如一地出现[21]。因此，需要进行多层次的分段融合来整合基于分段的检测结果，形成更全面、更鲁棒的受试者级抑郁症检测框架。

为了应对这些挑战，本文重点关注 MPDD-老年轨道，并提出了一种基于自适应时间窗口选择的多级分段融合（MSF-ATS）方法。我们根据比赛设置对两个时间窗口中的音频和视觉特征片段进行分类。然后，我们通过加权融合将不同特征的分段级分类结果结合起来，以获得每个时间窗口的主题级分类。随后，我们提出了一种基于平均类方差（MCV）的自适应时间窗口选择。通过比较不同时间窗口的MCV，我们在比赛中选择两个时间窗口划分中方差最小的时间窗口，从而获得更稳定的检测结果。实验结果表明，我们的方法在MPDD 2025官方测试集上取得了0.8576的平均得分，显著优于官方基线得分0.6675，从而证明了该方法在老年抑郁症检测任务中的有效性。

2方法

MSF-ATS如图1所示。第一部分是主题级分类，它利用音频、视觉和文本模态以及多级片段融合来获得每个时间窗口的主题级分类。第二部分是基于MCV的自适应时间窗口选择，通过比较不同时间窗口下的MCV来选择最合适的时间尺度，以获得更稳定和准确的检测结果。

2.1 学科层次分类

临床访谈中的抑郁症状通常只出现在简短的片段中，而不是在整个谈话中持续存在。为了捕获这些稀疏线索并生成具有临床意义的主题级分类，我们设计了一个主题级分类模块，该模块跨多种模式聚合分段级分类。在常见的分段级别设置中，来自同一参与者的所有音频或视频片段都被分配相同的标签 [8, 20]；然而，当缺乏明确的身份指示符时，模型可能无法利用跨片段一致性。为了解决这个问题，我们将文本派生的主题身份嵌入到每个视频或音频特征片段中，提供明确的从属关系信号，鼓励模型连贯地处理来自同一参与者的片段。

该模块中的所有输入特征均来自为 MPDD 2025 挑战赛提供的固定特征集。音频功能包括 Wav2Vec [19] 嵌入和梅尔倒谱系数 (MFCC) [17]。使用 DenseNet [11]、ResNet [9] 和 OpenFace [1] 提取视觉特征。表示受试者身份嵌入的文本特征是通过使用预训练的 RoBERTa [14] 模型并使用 [CLS] 令牌表示对受试者级人口统计和临床属性进行编码来获得的。

我们处理来自音频和视频模式的 $M = 5$ 个时间序列特征流。对于主题 s 、窗口大小 $\tau \in \{1s, 5s\}$ 和分段索引 j ，第 m 个流输入表示为 $X_{s,\tau,j,m} \in \mathbb{R}^{T_{s,\tau,j,m} \times D_m}$ ，其中 $T_{s,\tau,j,m}$ 表示时间维度， D_m 表示特征维度。为了简洁起见，当上下文清晰时，我们删除索引 s, τ, j 并写入 X_m 。

为了获得临时通知的固定长度摘要，我们采用 Okabe 等人[18]提出的注意力统计池（ASP）方法。每个序列首先通过全连接层进行处理，然后应用双曲正切激活函数：

$$F_m = \tanh(WX_m + b), \quad (1)$$

这里， W 和 b 是全连接层的权重和偏置， $\tanh(\cdot)$ 是双曲正切函数。输出 $F_m \in \mathbb{R}^{T_m \times D_m}$ 是非线性激活后的原始特征集。

我们使用可学习的查询向量 $p_m \in \mathbb{R}^{D_m}$ 计算时间步长的注意力权重，如下所示：

$$w_m = \text{softmax}(F_m \cdot p_m), \quad (2)$$

其中 softmax 沿着时间维度运行。 $\cdot$ 表示矩阵乘法，得到的 $w_m \in \mathbb{R}^{T_m}$ 表示每一帧的重要性。

时间注意力权重通过广播的逐元素乘法来调节原始序列：

$$X_m^{\text{att}} = w_m \odot X_m, \quad (3)$$




图1: 基于自适应时间窗口选择的多级分段融合 (MSF-ATS) 的整体架构。橙色线代表训练期间的数据流, 而蓝色线代表推理期间的数据流。

这里 $\odot$ 表示按元素相乘, 并在特征维度 D_m 上广播 w_m , 产生突出显示信息区域的 $X^{\text{att}}_m \in \mathbb{R}^{T_m \times D_m}$ 。

然后, 我们随时间应用全局总和池和标准差池, 并将两个统计数据连接起来:

$$x_m^{\text{pool}} = \left[\text{SUM}(X_m^{\text{att}}); \text{STD}(X_m^{\text{att}}) \right] \in \mathbb{R}^{2D_m}, \quad (4)$$

每个算子产生一个 D_m 维向量; 串联产生 $x_m^{\text{pool}} \in \mathbb{R}^{2D_m}$, 保留总体幅度和时间变化。

为了注入主体身份, 我们将池化向量与身份嵌入连接起来:

$$x'_m = [x_m^{\text{pool}}; id_s] \in \mathbb{R}^{2D_m+1024}, \quad (5)$$

其中 $id_s \in \mathbb{R}^{1024}$ 是主题 s 的主题身份。

接下来, 我们应用多层感知器 (MLP) 来获得分段级别的分类:

$$P_m = \text{MLP}_m(x'_m). \quad (6)$$

然后, 我们使用非负可靠性权重 $w_{\tau,m}$ 融合片段 (s, τ, j) 的 M 流预测。每个功能的段级

分类汇总为主题级别分类:

$$p_{s,\tau}^{\text{sub}} = \frac{1}{J_{s,\tau}} \sum_{j=1}^{J_{s,\tau}} \left(\sum_{m=1}^M w_{\tau,m} P_{s,\tau,j,m} \right), \quad (7)$$

其中 $P_{s,\tau,j,m}$ 是主题 s 和片段 j 在窗口大小 τ 下的第 m 个流的预测。项 $J_{s,\tau}$ 表示在窗口大小 τ 下主题 s 的分段总数。生成的 $p_{s,\tau}^{\text{sub}}$ 是窗口大小 τ 下主题 s 的主题级分类。

2.2 基于平均类别方差的自适应时间窗口选择

为了提高跨时间粒度的鲁棒性, 我们提出了一种基于 MCV 的自适应时间窗口选择。该策略选择时间窗口长度, 为每个分类任务产生更稳健的主题级分类。

我们将窗口 τ 下任务 t 的类 c 中的主题 s 的预测概率定义为 $p_{s,\tau,t,c}^{\text{sub}}$ 。接下来, 我们计算窗口 τ 下任务 t 的类平均概率:

$$\bar{p}_{\tau,t,c} = \frac{1}{N_{\tau,t,c}} \sum_{s=1}^{N_{\tau,t,c}} p_{s,\tau,t,c}^{\text{sub}} \quad (8)$$

其中 $\bar{p}_{\tau,t,c}$ 是窗口 τ 处任务 t 中类 c 的平均预测概率。 $N_{\tau,t,c}$ 表示每个类 c 、任务 t 和窗口大小 τ 的受试者总数。

然后我们计算相应的类别方差：

$$\sigma_{\tau,t,c}^2 = \frac{1}{N_{\tau,t,c}} \sum_{s=1}^{N_{\tau,t,c}} \left(p_{s,\tau,t,c}^{\text{sub}} - \bar{p}_{\tau,t,c} \right)^2, \quad (9)$$

其中 $\sigma_{\tau,t,c}^2$ 表示任务 t 中类 c 在窗口 τ 的预测概率的方差。

窗口 τ 处任务 t 的 MCV 计算如下：

$$\text{MCV}_{1s,t} = \frac{1}{C_t} \sum_{c=1}^{C_t} \sigma_{\tau_1,t,c}^2, \quad (10)$$

$$\text{MCV}_{5s,t} = \frac{1}{C_t} \sum_{c=1}^{C_t} \sigma_{\tau_5,t,c}^2, \quad (11)$$

这里， $\text{MCV}_{1s,t}$ 和 $\text{MCV}_{5s,t}$ 表示每个任务 t 在 $\tau \in \{1s, 5s\}$ 时间窗口计算的 MCV。

较低的 MCV 表示任务 t 在时间分辨率 τ 上的预测更一致。为了为每个任务选择最佳窗口，我们定义：

$$\hat{\tau}_t = \begin{cases} 1s, & \text{if } \text{MCV}_{1s,t} < \text{MCV}_{5s,t}, \\ 5s, & \text{otherwise}, \end{cases} \quad (12)$$

其中 $\hat{\tau}_t$ 表示基于 1s 和 5s 时间分辨率下 MCV 值的比较为任务 t 选择的最佳窗口大小。通过为每个任务选择 MCV 较低的窗口，我们可以选择更紧凑的时间窗口进行分类

2.3 损失函数

先前的工作证明了结合交叉熵 (CE) 和焦点损失来解决分类任务中的类不平衡问题的有效性[7,13,22]，我们在特征流训练阶段采用了类似的复合损失函数。具体来说，总损失定义为：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{CE}} \cdot \mathcal{L}_{\text{CE}} + \lambda_{\text{Focal}} \cdot \mathcal{L}_{\text{Focal}}, \quad (13)$$

其中 λ_{CE} 和 λ_{Focal} 是控制每个组件贡献的超参数。

CE 损失和焦点损失如下：

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{n=1}^N \sum_{c=1}^C y_{n,c} \log p_{n,c}, \quad (14)$$

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N} \sum_{n=1}^N \sum_{c=1}^C \alpha_c (1 - p_{n,c})^\gamma y_{n,c} \log p_{n,c}. \quad (15)$$

这里， C 是类的总数， N 是该批次中的样本总数。 $y_{n,c}$ 表示类 c 的样本 n 的真实标签， $p_{n,c}$ 是相应的 softmax 概率。 γ 是聚焦参数， α_c 是特定于类的平衡因子。 γ 和 α_c 都是根据数据分布凭经验设置的。

3 个实验

3.1 数据库

ACM Multimedia 2025 主办的 MPDD 2025 [7] 挑战赛为推进自动抑郁症检测的研究提供了标准化基准。它由两个轨道组成：MPDD-Elderly 专注于老年受试者的抑郁症检测，MPDD-Young 则针对年轻人。本文重点关注 MPDD-老年人，旨在利用多模式行为信号和人口特征对老年人的抑郁症状进行分类。

挑战赛包括三个分类级别：二元分类（正常与抑郁）、三元分类（正常、轻度抑郁、严重抑郁）和五元分类（正常、轻度抑郁、中度抑郁、中度严重、严重）。该数据集包含 337 个标记训练样本、227 个官方测试样本以及 78 个早期发布的用于模型选择的测试样本的附加子集。模型训练严格限于训练集，而早期发布的子集用于模型选择。最终评估是在完整的官方测试集上进行的。为了清楚起见，我们在本文的其余部分将早期发布的测试子集称为验证集。

由于隐私和道德限制，禁止直接访问原始音频、视频和文本数据；因此，挑战组织者只提供一组预先提取的多模式特征用于模型开发。这些特征跨越三个互补的流：视觉模态是通过 DenseNet [11]、ResNet [9] 和 OpenFace [1] 提取的。DenseNet 和 ResNet 是用于深度面部表示的卷积神经网络，而 OpenFace 则捕获动态面部特征，例如动作单元、注视方向和头部运动。音频模态包括 Wav2Vec [19] 嵌入、MFCC [17] 和 OpenSMILE [6]。Wav2Vec 是一种基于 Transformer 架构的自监督模型，它从原始音频信号中学习上下文感知表示，而 MFCC 则描述音频的频谱特征。OpenSMILE 是一个特征提取工具包，用于捕获韵律线索、情感和说话者特征。文本模态包括以结构化 JSON 格式提供的主题级元数据，例如人口统计和临床属性。这些描述是使用预训练的 RoBERTa 模型进行处理的，其中 [CLS] 令牌嵌入表示固定长度向量中的各个特征。

3.2 实验装置

实验是使用 PyTorch 框架进行的，并使用 Adam [12] 优化器进行模型训练。在第一阶段，所有训练和评估过程均在 NVIDIA GeForce RTX 4090D GPU 上执行。对于每个单峰特征，训练和超参数调整过程如下：首先，我们进行了全面的超参数搜索，探索不同的学习率，包括 1×10^{-3} 、 1×10^{-4} 和 1×10^{-5} 。CE 损失的权重固定为 1.0，而焦点损失的权重在不同范围内调整：从 0.01 到 0.1（步长 0.001）、从 0.1 到 1（步长 0.1）、从 1 到 10（步长 1）和 10 到 100（步长 10）。此外，Focal Loss 的 γ 值设置为 2、3 和 4。 α 还根据分类任务进行了调整：对于二元分类

分类, [0.25, 0.75]; 对于三元分类, [0.15, 0.25, 0.6]; 对于五元分类, [0.05, 0.1, 0.15, 0.25, 0.45]。

The classification layer uses an MLP with the following structure: $[2D_m + 1024, 1024, 512, 128, 64, \text{task_label}]$, where task_label denotes the number of classes for each specific subtask. 每个子任务的训练配置包括 256 个批量大小和 200 个训练时期。

The model that achieved the highest validation score—defined as the average of both weighted (w) and unweighted (u) Accuracy (Acc) and F1 scores was selected and saved. 具体而言, 评估 Score 计算如下:

$$\text{Acc}^w = \frac{1}{K} \sum_{k=1}^K \text{Acc}_{\text{task}_k}^w, \quad (16)$$

$$\text{Acc}^u = \frac{1}{K} \sum_{k=1}^K \text{Acc}_{\text{task}_k}^u, \quad (17)$$

其中 K 是任务总数, $\text{Acc}_{\text{task}_k}^w$ 和 $\text{Acc}_{\text{task}_k}^u$ 是任务 k 的加权和未加权准确度。

$$\text{F1}^w = \frac{1}{K} \sum_{k=1}^K \text{F1}_{\text{task}_k}^w, \quad (18)$$

$$\text{F1}^u = \frac{1}{K} \sum_{k=1}^K \text{F1}_{\text{task}_k}^u, \quad (19)$$

其中 $\text{F1}_{\text{task}_k}^w$ 和 $\text{F1}_{\text{task}_k}^u$ 是任务 k 的加权和未加权 F1 分数。

$$\text{Acc} = \frac{\text{Acc}^w + \text{Acc}^u}{2}, \quad (20)$$

$$\text{F1} = \frac{\text{F1}^w + \text{F1}^u}{2}, \quad (21)$$

$$\text{Score} = \frac{\text{Acc} + \text{F1}}{2}. \quad (22)$$

该分数用作在所有任务中选择最佳模型参数的标准。

在满足集合 $\{W_{\tau,m}\}_{m=1}^M$ 的条件下, 我们以 0.01 的步长从 0 到 1 进行搜索, 以确定使主题级分类得分最大化的最佳特征融合系数。该搜索是在验证集上进行的, 以确定将每个特征的分段级分类融合为主题级分类特征融合系数的最佳权重配置, 然后在测试阶段应用该系数。

3.3 结果和分析

我们评估了不同任务的验证集上每个特征的分段级分类得分。由于在我们的方法中使用 OpenSMILE 特征时损失不收敛, 因此我们排除了此特征。其余特征的性能如表 1 所示。在视觉模态中, DenseNet 在 6 个任务中的 4 个中优于其他视觉特征。具体来说, 它在 1s 二元 (1s_2) 任务上获得了 0.8785 的分数, 在 1s 五元 (1s_5) 任务上获得了 0.7018 的分数, 在 5s 二元 (5s_2) 任务上获得了 0.8952 的分数, 在 5s 五元 (5s_5) 任务上获得了 0.7721 的分数。ResNet 在 1s 三元 (1s_3) 任务上表现最佳, 得分为 0.6979, 在 5s 三元 (5s_3) 任务上表现最佳, 得分为 0.7020。相比之下,

表 1: 不同任务验证集上每个特征的分段级分类分数

Feature	1s_2	1s_3	1s_5	5s_2	5s_3	5s_5
DenseNet	0.8785	0.6476	0.7018	0.8952	0.6532	0.7721
ResNet	0.8371	0.6979	0.5772	0.8371	0.7020	0.6048
OpenFace	0.8347	0.5394	0.4753	0.7116	0.4958	0.4509
Wav2Vec	0.7647	0.6300	0.5987	0.7597	0.6902	0.6062
MFCCs	0.8662	0.6798	0.6600	0.8569	0.6283	0.6600

与所有任务中的其他视觉特征相比, OpenFace 始终表现不佳, 尤其是在两个五元任务中, 它在 1s_5 任务上获得了较低的分数 0.4753, 在 5s_5 任务上获得了 0.4509 的分数。在音频模式中, MFCC 在六项任务中的五项中优于 Wav2Vec, 在 1s_2、1s_3、1s_5、5s_2 和 5s_5 任务中分别获得了 0.8662、0.6798、0.6600、0.8569 和 0.6600 的分数。Wav2Vec 仅在 5s_3 任务中超越了 MFCC, 得分为 0.6902。结果表明, 基于深度学习的视觉特征在分段级分类中优于传统的手工特征, 而 MFCC 在基于音频的检测中优于 Wav2Vec 特征。

表 2: 不同任务验证集上多级分段融合的主题级分类得分

Task	Score
1s_2	1.0000
1s_3	0.9038
1s_5	0.7306
5s_2	1.0000
5s_3	0.9230
5s_5	0.8509

在获得验证集上每个特征片段级别分类的最佳模型后, 我们将多级别片段聚合为主题级别分类。结果如表 2 所示。对于二分类任务, 1s_2 和 5s_2 任务均获得了 1.0000 的满分, 展示了模型对较简单任务的强大判别能力。对于三元分类任务, 1s_3 和 5s_3 任务的得分分别为 0.9038 和 0.9230, 显示出相对于所有单峰特征的显着改进。在更复杂的五元分类任务中, 1s_5 和 5s_5 任务的得分分别为 0.7306 和 0.8509, 其中 5s_5 任务与表现最佳的单峰特征相比提高了 7 个百分点以上。这些结果表明, 与单峰分段级分类模型相比, 我们的融合策略更有效地利用多个特征的分类结果作为线索。通过为每个特征分配不同的权重, 然后将分段级别的分类聚合为主题级别的分类, 该策略不仅充分利用了多模态信息的优势, 而且还整合了不同分段的抑郁症分类结果, 以实现更准确的主题级别抑郁症检测, 从而显著提高了模型在各种分类任务中的性能。

表 3: 测试集上每个任务的最佳融合权重和分数

Modality	1s_2	1s_3	1s_5	5s_2	5s_3	5s_5
DenseNet	0.26	0.06	1.00	0.06	0.00	0.19
MFCCs	0.24	0.19	0.00	0.30	0.00	0.00
OpenFace	0.42	0.03	0.00	0.59	0.57	0.81
ResNet	0.06	0.12	0.00	0.05	0.26	0.00
Wav2Vec	0.02	0.60	0.00	0.00	0.17	0.00
Score	0.9707	0.8102	0.7191	1.0000	0.7996	0.7627

对于每个任务，选择验证分数最高的前 10 个配置进行测试评估，并选择产生最佳测试分数的配置作为最终设置。表 3 列出了测试集上每个任务的最佳融合权重和分数。与在分段级分类中的表现相比，OpenFace 在单分段分类中表现最差，但在主题级分类中实现了最高的融合权重。例如，OpenFace 在 5s_2、5s_3 和 5s_5 任务中的融合权重超过 0.5。结果表明，与其他功能相比，OpenFace 可能有助于解决访谈期间抑郁症状的稀疏性问题，使其成为在较长时间窗口的任务中评估受试者抑郁状态的有价值的功能。

表 4: 时间窗口选择对测试集中分类分数的影响

Strategy	Score
1s	0.8333
5s	0.8541
MCV	0.8576

表4给出了测试集上1s和5s等固定时间窗的得分，以及基于 MCV的多时间窗自适应时间窗选择。结果显示，MCV 取得了最高分 0.8576，在 1 秒和 5 秒窗口中均优于抑郁症检测。这表明使用多个时间窗口段和适当的时间窗口选择策略有助于增强抑郁症检测模型的有效性。

表 5: 测试集上的排行榜分数比较

Submission	Score
Baseline	0.6675
1st Place	0.8623
2nd Place	0.8580
Ours (3rd)	0.8576

最后，我们将我们的方法与 MPDD 2025 挑战赛中提交的官方排行榜进行了比较。如表5所示，我们的

方法的测试得分为0.8576，排名第三，显着超过基线[7]得分0.6675。前两支队伍的得分分别为 0.8623 和 0.8580，与我们的结果差异很小，进一步证明了我们模型的竞争力。这些结果凸显了 MSF-ATS 的有效性及其在现实世界临床抑郁症检测中的潜力。

4结论

在本文中，我们提出了 MSF-ATS 方法，应用于 MPDD 2025 挑战赛的 MPDD-老年人赛道。为了解决临床访谈期间抑郁症状的间歇性，我们的方法首先对音频和视觉特征进行分段级分类，并将这些分段级分类结果聚合到主题级分类中，形成多级分段融合。这种方法有效地利用了多模态信息，同时考虑了分段水平上抑郁症状的间歇性，从而产生更稳定的受试者水平检测。此外，我们引入了基于平均类方差的自适应时间窗口选择，允许模型根据稳定性动态调整最佳时间窗口。实验结果表明，我们的方法在 MPDD 2025 官方测试集上取得了 0.8576 的平均分数，显着优于基线分数，从而验证了我们方法的有效性。未来我们会考虑集成更多的特征来增强模型的抑郁症检测能力。此外，我们将研究切片持续时间对抑郁检测的影响，并优化时间窗口选择机制，以推动多模态抑郁诊断向临床部署的发展。

致谢

这项工作得到了国家自然科学基金委 62476057 号资助、中国科协 YESS 项目 2023QNRC001 资助、中国科学院 ASFC 2023 Z071069003 项目资助、东南大学至善青年学者计划资助、中国科协 YESS 项目 2023QNRC001 资助JSTJ-2023-XH033，部分由中国博士后科学基金项目2023M740600资助，部分由江苏省优秀博士后项目资助。

参考

[1] 塔达斯·巴尔特鲁萨蒂斯、彼得·罗宾逊和路易斯·菲利普·莫伦西。2016.Open face: 开源面部行为分析工具包。2016年IEEE计算机视觉应用冬季会议（WACV）。IEEE, 1-10。[2] 陈健、胡玉柱、赖奇峰、王伟、陈俊鑫、刘汉、Gautam Srivastava、Ali Kashif Bashir 和胡西平。2024. IIFDD: 使用来自医疗物联网的多模态信息进行抑郁症检测的模内和模间融合。信息融合102（2024），1 02017。[3]陈涛，洪日昌，郭艳荣，郝士杰，胡斌。2022. MS²-GNN: 探索基于 GNN 的多模态融合网络进行抑郁症检测。IEEE 控制论学报 53, 12 (2022), 7 749–7759。[4] 杰弗里·F·科恩、尼古拉斯·康明斯、朱利安·埃普斯、罗兰·戈克、乔蒂·乔希和斯特凡·谢勒。2018.从行为信号对抑郁症进行多模式评估。多模态多传感器接口手册：信号处理、架构以及情感和认知检测 - 第 2 卷 (2018), 375-417。[5] Sri Harsha Dumpala、Sebastian Rodriguez、Sheri Rempel、Mehri S. Ajjadian、Rudolf Uher 和 Sageev Oore。2022.利用说话人嵌入的时间上下文来检测抑郁症。过程。AAAI SAS (2022)。[6] 弗洛里安·埃本、马丁·沃尔默和比约恩·舒勒。2010. Opensmile: 慕尼黑多功能且快速的开源音频特征提取器。第 18 届 ACM 国际多媒体会议论文集。1459–1462。

[7] 付长增, 付泽林, 张琪, 匡新和, 董家成, 苏凯峰, 苏一凯, 史文波, 姚俊峰, 赵玉良, 等。2025。第一个 MPDD 挑战: 多模态人格感知抑郁症检测。arXiv 预印本 arXiv:2505.10034 (2025)。[8] 韩卓金, 商媛媛, 邵祝红, 刘静怡, 郭东, 刘铁, 丁辉, 胡强。2023。基于语音的抑郁症识别的时空特征网络。IEEE 认知和发展系统学报 16, 1 (2023), 308–318。[9] 何凯明, 张翔宇, 任少清, 孙健。2016。图像识别的深度残差学习。IEEE 计算机视觉和模式识别会议论文集。770–778。[10] Helen Herrman, Vikram Patel, Christian Kielling, Michael Berk, Claudia Buchweitz, Pim Cuijpers, Toshiaki A Furukawa, Ronald C Kessler, Brandon A Kohrt, Mario Maj 等。2022 年。针对抑郁症采取联合行动的时刻: 柳叶刀-世界精神病学协会委员会。《柳叶刀》399, 10328 (2022), 957–1022。[11] 高晃, 刘庄, Laurens van der Maaten, Kilian Q Weinberger。2017。密集连接的卷积网络。IEEE 计算机视觉和模式识别会议论文集。[12] Diederik P. Kingma 和 Jimmy Ba。2015。Adam: 随机优化方法。国际学习表征会议 (ICLR) (2015)。https://arxiv.org/abs/1412.6980 [13] 李朝阳, 路程, 徐晓林, 张凯飞, 谷雨佳, 李邦华, 宗远, 郑文明。2025。利用法学硕士增强任务特定特征学习, 以实现多模态情感和意图联合理解。在 ICASSP 2025 - 2025 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。1-2。doi:10.1109/ICASSP49660.2025.10890555 [14] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer 和 Veselin Stoyanov。2019。Roberta: 一种稳健优化的 bert 预训练方法。arXiv 预印本 arXiv: 1907.11692 (2019)。

[15] 丹尼拉·马蒙托夫、塞巴斯蒂安·泽普夫、阿列克谢·卡尔波夫和沃尔夫冈·明克。2024。基于音频信号的跨文化自动抑郁症检测。在国际语音和计算机会议上。施普林格, 309-323。[16] 毛凯宁, 张伟, 王宝峰, 李安, 焦荣奇, 朱艳辉, 吴斌, 郑天生, 钱磊, 吕伟, 等。2022。基于双向 LSTM 和时间分布式 CNN 的韵律和语义特征预测抑郁症严重程度。IEEE 情感计算交易 14, 3 (2022), 2251–2265。[17] 布莱恩·麦克菲、科林·拉斐尔、梁大文、丹尼尔·PW·埃利斯、马特·麦克维卡、埃里克·巴滕伯格和奥里奥尔·涅托。2015。librosa: Python 中的音频和音乐信号分析。SciPy 2015 (2015), 18-24。[18] 冈部浩二、小辛高文、筱田浩一。2018。用于深度说话人嵌入的统计池。arXiv 预印本 arXiv:1803.10963 (2018)。[19] 史蒂芬·施奈德、阿列克谢·巴耶夫斯基、罗南·科洛伯特和迈克尔·奥利。2019。wav2vec: 语音识别的无监督预训练。arXiv 预印本 arXiv:1904.05862 (2019)。[20] 布拉克·塔斯基奇。2024。基于语音的抑郁症识别方法的多级混合手工特征提取。情感障碍杂志 364 (2024), 9–19。[21] Jinhan Wang, Vijay Ravi, Jonathan Flint 和 Abeer Alwan。2024。Speechformer-ctc: 使用语音时间分类的抑郁症检测的序列建模。语音交流163(2024), 103106。[22] 徐晓林, 陆程, 李朝阳, 刘雨云, 马英豪, 罗家豪, 宗远, 郑文明。2025。从法学硕士特征中可靠地学习多模态情感和意图联合理解。在 ICASSP 2025 - 2025 IEEE 声学、语音和信号处理国际会议 (ICASSP) 中。1-2。doi:10.1109/ICASSP49660.2025.10888958 [23] 张伟, 朱恩, 陈娟, 李云鹏。2024。MDDR: 用于抑郁症识别的多模态双注意力聚合。第 32 届 ACM 国际多媒体会议论文集。321–329。